

ENSEIGNANT : MOUJTABA OULD TALEB DIT CHEIBA



Moujtaba Ould Taleb Dit Cheiba

Filière : SAE - 1

Année universitaire : 2023/2024

Table des matières

Chapitre 1. Historique et Vocabulaire	3
I. Historique et méthodes statistiques.....	3
A. Historique.....	3
B. Méthodes statistiques.....	3
II. Vocabulaires	3
A. Introduction	3
B. Terminologie	4
C. Différents types de variables statistiques	4
Chapitre 2. Série statistique univariée	6
I. Représentations graphiques	6
A. Variables qualitatives	6
B. Variables discrètes	6
C. Variables continues.....	7
II. Représentations numériques	9
A. Paramètres de position (Paramètres de tendance centrale).....	9
B. Paramètres de dispersion	13
C. Paramètres de dispersion relative	14
D. Paramètres de forme.....	15
E. Paramètres de concentration.....	16
Chapitre 3 : Indices statistiques.....	18
I. Indices élémentaires	18
II. Les indices synthétiques	19

Chapitre 1. Historique et Vocabulaire

I. Historique et méthodes statistiques

A. Historique

Aussi loin que l'on remonte dans le temps et dans l'espace (en Chine et en Égypte, par exemple), les États ont toujours senti le besoin de disposer d'informations sur leurs sujets ou sur les biens qu'ils possèdent et produisent. Mais les recensements de population et de ressources, les statistiques (du latin status : état) sont restées purement descriptives jusqu'au 17^{ème} siècle. Puis s'est développé le calcul des probabilités et des méthodes statistiques sont apparues en Allemagne, en Angleterre et en France.

Beaucoup de scientifiques de tout ordre ont apporté leur contribution au développement de cette science : Pascal, Bernoulli, Moivre, Laplace, Gauss, Mendel, Pearson, Fischer etc....

Actuellement, beaucoup de domaines utilisent les méthodes statistiques (médecine, agronomie, sociologie, industrie etc....).

B. Méthodes statistiques

- 1^{ère} étape : On collecte des données :
 - ◊ Soit de manière exhaustive
 - ◊ Soit par sondage
- 2^{ème} étape : On traite les données que l'on organise en tableaux, diagrammes, etc...
- 3^{ème} étape : On interprète les résultats : on les compare avec ceux déduits de la théorie des probabilités.

On pourra donc :

- Evaluer une grandeur statistique comme la moyenne ou la variance (estimateurs, intervalles de confiance).
- Savoir si deux populations sont comparables (tests d'hypothèses).
- Déterminer si deux grandeurs sont liées et de quelle façon (corrélation, ajustement analytique).

Les conclusions, toujours entachées d'un certain pourcentage d'incertitude, nous permettent alors de prendre une décision.

II. Vocabulaires

A. Introduction

La Statistique est l'ensemble de méthodes et outils mathématiques visant à collecter, décrire et analyser des données afin d'obtenir de l'information permettant de prendre des décisions malgré la présence d'incertitude.

La statistique est l'outil de confrontation d'une théorie scientifique à l'observation.

La statistique descriptive est l'étude de résultats observés (statistiques) sur des ensembles comportant un grand nombre d'observations dans le but de les condenser pour en avoir une vue synthétique. Ce condensé se fera en perdant un certain nombre d'observations mais en gardant l'allure générale du phénomène étudié.

B. Terminologie

- **Population** : c'est l'ensemble d'éléments présentant caractère commun. Pour une thématique donnée, la population regroupe toujours la totalité des individus relatifs à cette thématique (notion d'exhaustivité).
- **Individu/Unité statistique** : C'est l'élément de base constitutif de la population à laquelle il appartient. Il est indivisible et peut être un pays, un végétal, un humain ou une entreprise.
- **Echantillon** : C'est un sous-ensemble construit et représentatif d'une population donnée. Le nombre d'individus dans l'échantillon est la Taille de l'échantillon.
- **Caractère/Variable statistique (x)** : C'est la propriété ou l'aspect singulier que l'on se propose d'observer dans la population ou l'échantillon. Un caractère qui fait le sujet d'une étude porte aussi le nom de Variable statistique.
- **Modalités (x_i)** : Ce sont les différentes valeurs que peut prendre le caractère précédemment défini.
- **Effectif (n_i)** : C'est le nombre de répétition d'une modalité
- **Paramètre** : mesure numérique décrivant une caractéristique de la population.
- **Une statistique** : mesure numérique décrivant une caractéristique de l'échantillon
- **Donnée** : fait numérique ou non porteur d'information.

C. Différents types de variables statistiques

Chaque individu d'une population peut être décrit par une ou plusieurs **variables**. Ces variables peuvent être

- **Variable qualitative** : caractéristiques qui prennent des modalités non numériques. Une variable qualitative peut être :
 - **nominale** : données non numériques qui ne peuvent pas être ordonnées (genre). Une variable est dite **dichotomique** : si elle ne prend que 2 modalités (comme le genre qui prends les modalités : Homme, Femme)
 - **ordinaire** : données non numériques possédant un ordre naturel (avis pédagogiques)
Exemple : Un questionnaire de satisfaction demande aux consommateurs d'évaluer une prestation en cochant l'une des six catégories suivantes : (a) nulle, (b) médiocre, (c) moyenne, (d) assez bonne, (e) très bonne, (f) excellente. Il s'agit de modalités ordinaires puisqu'elles peuvent être hiérarchisées : une prestation excellente est meilleure qu'une prestation bonne, ..., etc.
- **Variable quantitative** : variable numérique qui peut être :
 - **discrète** : valeurs numériques discrètes, isolées.
Exemple : On a questionné 100 ménages sur le nombre d'ampoules électriques utilisées dans leur domicile. Les données sont regroupées par nombre d'ampoules.
 - **continue** : valeurs numériques sur un intervalle continu.
Exemple : On a mesuré 20 personnes et les résultats sont (en cm)
- **Distribution** : Pour une série d'observations relatives à une variable statistique X , la distribution statistique de cette variable est la donnée d'un ensemble de valeurs (ou classes) et de leur effectifs (ou fréquences) associée.

Les données brutes sont souvent collectées dans tableau dit **Tableau des données** :

Variables Individus	X_1	...	X_k	...	X_p
1	$x_{1,1}$	...	$x_{1,k}$	...	$x_{1,p}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
i	$x_{i,1}$	...	$x_{i,k}$	...	$x_{i,p}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
N	$x_{N,1}$	...	$x_{N,k}$	...	$x_{N,p}$

▪ N est nombre d'individus ou **Taille** de la population ou de l'échantillon à étudier ;

▪ p est le nombre de variables étudiées ;

▪ $x_{i,k}$ est la valeur de la k-ème variable mesurée sur le i-ème individu.

Ce tableau est appelé **série statistique à p dimensions**

Exemple.

Le tableau suivant résume des données d'un petit échantillon et sur un petit nombre de variables, choisis à titre illustratif, des données de l'*Enquête Permanente sur les Conditions de Vie de ménages* réalisée par l'Office National de la Statistiques (ONS)

Nombre de personne	Age du chef	Niveau d'éducation	Groupe socio-économique	Milieu	Dépense mensuelle
5	60	0	1	2	60418
7	42	3	4	2	28083
3	42	3	4	2	87777
6	45	2	5	2	33806
5	37	1	5	1	109695
2	70	4	3	1	96198
5	50	0	4	1	111463
4	32	0	1	1	47944
2	41	1	4	1	38642
5	60	5	4	1	45660

La **population** étudiée est l'ensemble des ménages mauritaniens. Les données disponibles sont celles d'un **échantillon**. Chaque ménage constitue une **unité statistique** (individu). Plusieurs **paramètres** sont concernés par l'étude, citons par exemple l'incidence de la pauvreté, la proportion des ménages dont les chefs sont des femmes, l'âge moyen des chefs de ménage etc. Comme l'enquête ne porte que sur un échantillon, ces paramètres vont être estimés par des statistiques calculées à partir des données de l'échantillon. Les variables de ce tableau sont :

- Nombre de personnes qui composent le ménage : variable quantitative discrète ;
- Age du chef de ménage : Variable quantitative continue ;
- Niveau d'instruction du chef de ménage : variable qualitative ordinale ;
- Groupe socio-économique : variable qualitative nominale ;
- Milieu où le ménage habite : variable qualitative nominale à deux modalités, urbain ou rural, donc dichotomique. Dépense mensuelle : variable quantitative continue

La dernière ligne correspond à un ménage composé de 5 personnes, dont le chef est âgé de 60 ans, ayant un niveau d'études supérieures (Niveau =5) et qui est inactif (GSE=4). Ce ménage habite en milieu rural (milieu=2) et dépense mensuellement 45 660 UM.

Chapitre 2. Série statistique univariée

I. Représentations graphiques

A. Variables qualitatives

La description d'une population selon une variable qualitative est totalement résumée dans un tableau de pourcentages ou dans un **diagramme circulaire**, appelé aussi **diagramme en camembert**

Modalités	Modalité 1 (x_1)	Modalité 2 (x_2)	...	Modalité k (x_k)	...	Modalité k (x_k)	Total
Effectifs	n_1	n_2	...	n_i	...	n_k	N


- n_i est le nombre de fois où apparaît la modalité k dans la série il est appelé **effectif** de la modalité i ;
- k est le nombre de modalités distinctes observées ;
- La série univariée est donc **résumée** par $\{(x_1, n_1); \dots, (x_i, n_i); \dots; (x_k, n_k)\}$;
- Les **fréquences** $f_i = \frac{n_i}{n}$ représentent la fréquence d'observations qui sont égales à x_i ;

Modalités	Modalité 1 (x_1)	Modalité 2 (x_2)	...	Modalité i (x_i)	...	Modalité k (x_k)	Total
Effectifs	n_1	n_2	...	n_i	...	n_k	N
Fréquence	f_1	f_2	...	f_i	...	f_k	1

- Le **diagramme en secteurs** est une représentation graphique à l'aide d'un disque découpé en secteurs. À chaque modalité observée correspond un secteur. Les angles α_i des secteurs sont proportionnels aux effectifs représentés. Ces angles sont donnés par $\alpha_i = 360 \times f_i$

Exemple : Répartition de populations de Nouakchott selon les Moughataa

Moughataa	Population
Teyarett	78 828
Ksar	47 233
TevraghZeina	46 336
Toujounine	144 041
Sebkha	72 245
El Mina	132 674
Dar Naïm	144 043
Arafat	175 969
Riad	117 030
Total Nouakchott	958 399



Source : ONS/ RGPH 2014

B. Variables discrètes

Considérons une variable observée sur une population de n individus. Si la variable X prend k valeurs ou ensembles de valeurs (appelés dans ce qui suit, modalités), le premier traitement des données brutes consiste à compter le nombre n_i (appelé **effectif**) d'individus qui présentent la i -ème modalité

Soit le **tableau récapitulatif** de la variable

Modalités	x_1	...	x_i	...	x_k	Total
Effectifs	n_1	...	n_i	...	n_k	N
Fréquence	f_1	...	f_i	...	f_k	1
Effectif cumulé croissante	N_1^+	...	N_i^+	...	N_k^+	
Effectif cumulé décroissante	N_1^-	...	N_i^-	...	N_k^-	
Fréquence cumulée croissante	F_1^+	...	F_i^+	...	F_k^+	
Fréquence cumulée décroissante	F_1^-	...	F_i^-	...	F_k^-	

Notations :

 $N = \sum_{j=1}^k n_j$ est l'effectif total. $f_i = \frac{n_i}{N}$ est la fréquence. $N_i^+ = \sum_{j=1}^i n_j$ est l'effectif cumulé croissant. N_i^- est l'effectif cumulé décroissant. $F_i^+ = \sum_{j=1}^i f_j = \frac{N_i^+}{n}$ est la fréquence cumulée croissante. $F_i^- = \frac{N_i^-}{n}$ est la fréquence cumulée décroissante.

■ Diagramme en bâtons :

Il est construit dans un système d'axes rectangulaires ; les valeurs de la variable statistique X sont portées en abscisse à partir de chaque modalité on trace un segment de droite vertical et dont la hauteur est proportionnelle à l'effectif correspondant. On peut retenir indifféremment une échelle qui explicite les effectifs ou une échelle qui explicite les fréquences.

Exemple. On interroge 100 ménages sur le nombre de pièces de leur logement. On obtient le tableau suivant :

x_i	n_i	f_i	N_i^+	N_i^-	F_i^+	F_i^-
1	5	0,05	5	100	0,05	1,00
2	30	0,3	35	95	0,35	0,95
3	40	0,4	75	65	0,75	0,65
4	20	0,2	95	25	0,95	0,25
5	5	0,05	100	5	1,00	0,05




Diagramme en bâton

C. Variables continues

Le domaine de variation d'une variable statistique continue X est partagé en k parties. L'intervalle

$[e_{i-1}; e_i[$ fermé à gauche, ouvert à droite, est appelé i -ème **classe** ($i = 1, 2, \dots, k$) ; son amplitude est égale à $a_i = e_i - e_{i-1}$.

Il arrive que l'**amplitude** des classes extrêmes soit indéterminée : la première classe étant définie par « moins de... », et la dernière par « plus de... ». Le choix des *extrémités* des classes se fait à partir des données brutes. Le nombre de classe doit être modéré entre 4 et 10.

Une **classe** est un intervalle $[e_{i-1} - e_i[$; son centre ou milieu est : $c_i = \frac{e_i + e_{i-1}}{2}$.

Le nombre d'observations dans la classe k est noté n_i et est appelé effectif de la classe. On résume les données dans le **tableau récapitulatif** de la variable.

Classe	$[e_0 - e_1[$	$[e_1 - e_2[$	$\dots$	$[e_{i-1} - e_i[$	$\dots$	$[e_{k-1} - e_k[$	Total
Centre	c_1	c_2	$\dots$	c_i	$\dots$	c_k	
Amplitude	a_1	a_2	$\dots$	a_i	$\dots$	a_k	
Effectifs	n_1	n_2	$\dots$	n_i	$\dots$	n_k	N
Fréquence	f_1	f_2	$\dots$	f_i	$\dots$	f_k	1
Effectif cumulé croissant	N_1^+	N_2^+	$\dots$	N_i^+	$\dots$	n	
Fréquence cumulée croissante	F_1	F_2	$\dots$	F_i	$\dots$	1	

- **Histogramme.** À la i -ème classe, correspond un rectangle dont la base est l'intervalle $[e_{i-1}; e_i[$ et dont la surface est proportionnelle à la fréquence f_i (ou à l'effectif n_i). Si les classes ont toutes la même amplitude, les densités des rectangles sont proportionnelles aux fréquences (ou aux effectifs). Dans le cas où les classes sont d'amplitudes inégales, la densité du rectangle correspondant à la i -ème classe d'amplitude a_i sera $d_i = \frac{f_i}{a_i}$. La surface du rectangle représentant la i -ème classe sera ainsi égale à f_i . On peut également utiliser les effectifs ou les fréquences cumulées.

- **Polygone** relie le centre de l'histogramme par des segments.
- **Fonction de répartition** est une fonction croissante telle que :

- $F(x) = 0$ pour tout $x \leq \min x_i$
- $F(x) = 1$ pour tout $x \geq \max x_i$
- Si $x \in [e_{i-1} - e_i[$

$$F(x) = \frac{F_{i-1}^+}{a_i}(x - e_{i-1}) + \frac{F_i^+}{a_i}(e_i - x) = F_{i-1}^+ + \frac{f_i}{a_i}(x - e_{i-1})$$

- **Fonction de répartition à droite**


- $F^*(x) = 1$ pour tout $x \leq \min x_i$
- $F^*(x) = 0$ pour tout $x \geq \max x_i$
- Si $x \in [e_{i-1} - e_i[$; $F^*(x) = F_i^- - \frac{f_i}{a_i}(x - e_{i-1})$

$F(x)$ = Proportion des observations inférieurs ou égal à x .

$F^*(x)$ = Proportion des observations supérieurs ou égal à x .

Exemple. On a mesuré la taille de 20 personnes et les résultats sont (en cm) : {148, 165, 145, 173, 148, 145, 152, 180, 130, 170, 170, 170, 142, 148, 165, 175, 180, 180, 180, 180}. En les regroupant en 5 classes d'amplitudes égales on obtient

$[e_{i-1}; e_i[$	c_i	n_i	f_i	N_i^+	N_i^-	F_i^+	F_i^-
[130-140[	135	1	0,05	1	20	0,05	1,00
[140-150[	145	6	0,30	7	19	0,35	0,95
[150-160[	155	1	0,05	8	13	0,4	0,65
[160-170[	165	2	0,10	10	12	0,5	0,60
[170-180]	175	10	0,50	20	10	1,00	0,50



Diagrammes des fréquences cumulées croissantes et décroissantes

II. Représentations numériques

Le tableau de distribution d'une variable statistique présente l'information recueillie sur cette variable. Une représentation graphique en fournit un portrait pour appréhender plus facilement la globalité de l'information. On peut désirer aller plus loin en cherchant à caractériser la représentation visuelle par des éléments synthétiques sur :

- La valeur de la variable située au « centre » de la distribution : la *tendance centrale* et, plus généralement, un *indicateur de position* non nécessairement centrale, liée à un rang donné ;
- La variation des valeurs : la *dispersion* ;
- La *forme* de la distribution ;
- Les aspects particuliers : comme les valeurs *extrêmes*.

Ces indicateurs étant exprimés dans les unités de la variable étudiée. Pour comparer plusieurs distributions entre elles il est intéressant de calculer des *caractéristiques de dispersion relative*.

A. Paramètres de position (Paramètres de tendance centrale)

1. Les moyennes

▪ Moyenne arithmétique $\bar{x}$

On appelle *moyenne arithmétique* la somme de toutes les données statistiques divisée par le nombre de ces données. Elle se calcule pour les variables quantitatives comme suit :

Les données brutes	Les données agrégées	Les données regroupées en classe
$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ $= \frac{1}{N} (x_1 + \dots + x_N)$	$\bar{x} = \frac{1}{N} \sum_{i=1}^k n_i x_i$ $= \frac{1}{N} (n_1 x_1 + \dots + n_k x_k)$ $\bar{x} = \sum_{i=1}^k f_i x_i$	$\bar{x} = \frac{1}{N} \sum_{i=1}^k n_i c_i$ $= \frac{1}{N} (n_1 c_1 + \dots + n_k c_k)$ $\bar{x} = \sum_{i=1}^k f_i c_i$

Propriétés

- Sensible face aux points aberrants.
- La somme algébrique des écarts des valeurs d'une variable statistique à sa moyenne arithmétique est nulle. $\sum_{i=1}^k (x_i - \bar{x}) = 0$.
- La série centrée est obtenue en retranchant de chaque valeur la moyenne, c.-à-d, $\{x_i - \bar{x}\}$. La moyenne de la série centrée vaut toujours 0. $\sum_{i=1}^k f_i (x_i - \bar{x}) = 0$.
- Lorsqu'on fait subir à une variable statistique x une transformation affine, c'est-à-dire un changement d'origine et d'unité $\{y = ax + b\}$, sa moyenne arithmétique subit la même transformation : $\bar{y} = a\bar{x} + b$.
- Soit p séries de tailles $n_1, \dots, n_p$ et de moyennes respectives $\bar{x}_1, \dots, \bar{x}_p$ alors la moyenne de la série obtenue en regroupant toutes les séries est donnée par

$$\bar{x} = \frac{n_1\bar{x}_1 + \dots + n_p\bar{x}_p}{n_1 + \dots + n_p}.$$

■ **Moyenne quadratique**

C'est la racine carrée de la moyenne arithmétique des carrés. On l'utilise quand on a une alternance de valeurs positives et négatives comme suit :

Les données brutes	Les données agrégées	Les données regroupées en classe
$Q = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$ $= \sqrt{\frac{1}{N} (x_1^2 + \dots + x_N^2)}$	$Q = \sqrt{\frac{1}{N} \sum_{i=1}^k n_i x_i^2}$ $= \sqrt{\frac{1}{N} (n_1 x_1^2 + \dots + n_k x_k^2)}$ $= \sqrt{\sum_{i=1}^k f_i x_i^2}$	$Q = \sqrt{\frac{1}{N} \sum_{i=1}^k n_i c_i^2}$ $= \sqrt{\frac{1}{N} (n_1 c_1^2 + \dots + n_k c_k^2)}$ $= \sqrt{\sum_{i=1}^k f_i c_i^2}$

■ **Moyenne géométrique**

C'est la moyenne applicable à des mesures de grandeurs dont la croissance est géométrique. La moyenne géométrique a pour expression :

Les données brutes	Les données agrégées	Les données regroupées en classe
$G = \sqrt[N]{\prod_{i=1}^N x_i}$	$G = \sqrt[N]{\prod_{i=1}^k x_i^{n_i}}$	$G = \sqrt[N]{\prod_{i=1}^k c_i^{n_i}}$

- **Exemple :** Supposons que pendant une décennie, les salaires aient été multipliés par 2 et que pendant la décennie suivante, ils aient été multipliés par 4 ; le coefficient multiplicateur moyen par décennie est égal à : $\sqrt{2.4} = \sqrt{8} \approx 2,83$.
La moyenne arithmétique (= 3) n'est pas égale au coefficient demandé.

▪ Moyenne harmonique

La *moyenne harmonique* notée H , est l'inverse de la moyenne arithmétique des inverses des valeurs. El a pour expression :

Les données brutes	Les données agrégées	Les données regroupées en classe
$H = \frac{N}{\sum_{i=1}^n \frac{1}{x_i}}$	$H = \frac{N}{\sum_{i=1}^k \frac{n_i}{x_i}} = \frac{1}{\sum_{i=1}^k \frac{f_i}{x_i}}$	$H = \frac{N}{\sum_{i=1}^k \frac{n_i}{c_i}} = \frac{1}{\sum_{i=1}^k \frac{f_i}{c_i}}$

➤ **Exemple :**

Le jour d'un devoir de statistique, un étudiant va de son domicile à la faculté à la vitesse 3 Km/h. Il en revient à la vitesse de 6 Km/h. quelle est sa vitesse moyenne ?

La vitesse moyenne de parcours à aller au retour est égal à :

$$\frac{2}{\frac{1}{3} + \frac{1}{6}} = 4 \text{ Km/h}$$

La moyenne arithmétique (= 4,5) ne représente pas la vitesse moyenne du parcours.

▪ Mode

Pour obtenir une mesure de la tendance centrale non influencée par les valeurs extrêmes de la distribution, on peut prendre la valeur – ou la classe de valeurs – du caractère pour laquelle le diagramme en bâtons – respectivement l'histogramme – présente son *maximum* : c'est le *mode* – respectivement la classe *modal* – de la distribution ; dans le cas où le diagramme en bâtons ou l'histogramme – présente aussi un maximum local, il y a deux modes – respectivement deux classes modales.

La présence de plusieurs modes peut être dû au fait que les données sont issues de populations différentes.

Le mode d'une distribution est noté M_o . C'est la valeur du caractère **la plus fréquente** ou dominante dans l'échantillon. Dans le cas discret, le mode est la valeur correspondante à l'effectif/fréquence le plus grand. Dans le cas continu classé, le mode est calculé à partir des hauteurs $\left\{h_i = \frac{n_i}{a_i}, i = 1 \text{ à } k\right\}$ des classes. On définit la classe modale $[e_{i-1} - e_i[$ comme étant celle de la plus grande hauteur. Pour déterminer le mode, on applique la formule suivante :

$$M_o = e_{i-1} + \frac{h_i - h_{i-1}}{(h_i - h_{i+1}) + (h_i - h_{i-1})} a_i.$$

Propriétés et remarques

- Le mode est facile à calculer
- Il s'exprime de mêmes unités que les données
- Si l'effectif maximum correspond à deux valeurs successives de la variable, la série est bimodal

■ Médiane, Quantiles et Boîte de Tukey

De façon générale le quantile d'ordre $p \in]0,1[$ est la valeur x_p telle que $F(x_p) = p$

Médiane $Mé$: c'est la valeur qui partage la série d'observation en deux parties égales 50% au-dessus de la médiane, et 50% en-dessous de la médiane.

- a. Pour une série d'observation non groupée $\{x_i, i = 1, \dots, n\}$, la médiane est l'observation au centre de la série ordonnée.

- Si N impair $Mé = x_{\frac{N+1}{2}}$
- Si N paire $Mé = \frac{x_{\frac{N}{2}} + x_{(\frac{N}{2}+1)}}{2}$. (la moyenne des deux observations au centre).

- b. Si la série est groupée il faut d'abord déterminer la classe médiane $[e_{i-1} - e_i[$. Il s'agit :

- De la classe correspondante au premier $N_i^+ \{i = 1, \dots, k\}$ qui est supérieur ou égal à $\frac{N}{2}$. Ensuite la médiane est donnée par :

$$Mé = e_{i-1} + \frac{\frac{N}{2} - N_{i-1}^+}{n_i} a_i.$$

- Ou de la classe pour laquelle $F_{i-1}^+ < 0.5$ et $F_i^+ \geq 0.5$. Ensuite la médiane est donnée par :

$$Mé = e_{i-1} + \frac{0.5 - F_{i-1}^+}{f_i} a_i.$$

c. Propriétés

- Pas influencée par des valeurs extrêmes.
- Pour des distributions dissymétriques, la médiane offre une meilleure représentation que la moyenne.
- La médiane représente la valeur au centre : la moitié est supérieure à cette valeur et l'autre moitié lui est inférieure.

Quantiles X_p

- Le premier quartile $Q_1 = e_{i-1} + \frac{\frac{N}{4} - N_{i-1}^+}{n_i} a_i = e_{i-1} + \frac{0.25 - F_{i-1}^+}{f_i} a_i$
- Le deuxième quartile $Q_2 = Mé$ (la médiane).
- Le troisième quartile $Q_3 = e_{i-1} + \frac{\frac{3N}{4} - N_{i-1}^+}{n_i} a_i = e_{i-1} + \frac{0.75 - F_{i-1}^+}{f_i} a_i$
- Le septième décile $D_7 = e_{i-1} + \frac{\frac{7N}{10} - N_{i-1}^+}{n_i} a_i = e_{i-1} + \frac{0.70 - F_{i-1}^+}{f_i} a_i$
- Le 78^{ème} centile $C_{78} = e_{i-1} + \frac{\frac{78N}{100} - N_{i-1}^+}{n_i} a_i = e_{i-1} + \frac{0.78 - F_{i-1}^+}{f_i} a_i$.
- Ect.....

Boîte à moustaches de Tukey

On trace un rectangle de largeur fixée à priori et de longueur $EIQ = (Q_3 - Q_1)$; et on y situe la médiane par un segment positionné à la valeur Q_2 , par rapport à Q_3 et Q_1 ; on a alors la boîte. On détermine et x_b la **valeur basse** qui est la plus petite valeur supérieure à $Q_1 - 1,5 EIQ$ et x_h la **valeur haute** qui est la plus grande valeur inférieure à $Q_3 + 1,5 EIQ$;

On trace deux lignes allant des milieux des largeurs du rectangle aux valeurs x_b et x_h

S'il y a des valeurs qui sont inférieures à x_b ou supérieures à x_h elles sont représentées par des points et sont considérées comme valeurs aberrantes ou extrêmes.

Exemple. Retour à l'exemple de la variable taille. On remarque que le $1^{\text{er}} N_i^+$ qui est supérieur ou égal à $\frac{N}{2}$ est $N_4^+ = 10$. Donc,

$$Q_2 = e_3 + \frac{\frac{N}{2} - N_3^+}{n_4} a_4 = 160 + 10 \times \frac{\frac{20}{2} - 8}{2} = 170. \text{ De même,}$$

- Le $1^{\text{er}} N_i^+$ qui est supérieur ou égal à $\frac{N}{4}$ est $N_2^+ = 7$. Donc,


$$Q_1 = e_1 + \frac{\frac{N}{4} - N_1^+}{n_2} a_2 = 140 + \frac{\frac{20}{4} - 1}{6} \times 10 = 146,67$$

- Le $1^{\text{er}} N_i^+$ qui est supérieur ou égal à $3 \frac{N}{4}$ est $N_5^+ = 20$. Donc,

$$Q_3 = e_4 + \frac{3 \frac{N}{4} - N_4^+}{n_5} a_5 = 170 + \frac{3 \frac{20}{4} - 10}{6} \times 10 = 175.$$

On a $Q_3 + 1,5 EIQ = 175 + 1,5 (175 - 146,67) = 217,5$.

et $Q_1 - 1,5 EIQ = 146,67 - 1,5 (170 - 146,67) = 104,17$. Donc, $x_h = 180$ et $x_b = 130$.

**B. Paramètres de dispersion**

1. **Etendue** : est l'écart entre la valeur minimale et la valeur maximale.

$$\text{Etendue} : E = x_{\max} - x_{\min}$$

2. **Ecart interquartile** $x_p - x_{1-p}$

$$\text{Ecart interquartile } EIQ = Q_3 - Q_1;$$

$$\text{Ecart interdécile} : EID = D_9 - D_1 ;$$

$$\text{Ecart intercentile} : EIC = C_{99} - C_1 \dots \text{Ect}$$

3. Variance et l'Ecart-type

Les données brutes	Les données agrégées	Les données regroupées en classe
$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^2$ $= \frac{1}{N} \sum_{i=1}^n x_i^2 - \bar{x}^2$	$\sigma^2 = \frac{1}{N} \sum_{i=1}^k n_i (x_i - \bar{x})^2$ $= \frac{1}{N} \sum_{i=1}^k n_i x_i^2 - \bar{x}^2$ $\sigma^2 = \sum_{i=1}^k f_i x_i^2 - \bar{x}^2$	$\sigma^2 = \frac{1}{N} \sum_{i=1}^k n_i (c_i - \bar{x})^2$ $= \frac{1}{N} \sum_{i=1}^k n_i c_i^2 - \bar{x}^2$ $\sigma^2 = \sum_{i=1}^k f_i c_i^2 - \bar{x}^2$

L'écart-type σ est la racine carrée de la variance.

Propriétés

- La variance et l'écart-type sont plus sensibles aux valeurs extrêmes que la moyenne, en raison des élévations au carré
- Soit une population de taille N composée de deux sous-populations de taille n_1 et de taille n_2 . Soit X , une variable statistique observée sur la population, alors

$$\sigma^2 = \frac{1}{N} (n_1 \sigma_1^2 + n_2 \sigma_2^2 + n_1 (\bar{x}_1 - \bar{x})^2 + n_2 (\bar{x}_2 - \bar{x})^2).$$

- Lorsque deux variables x et y sont en correspondance par le changement d'origine b et le changement d'échelle a ; $y = ax + b$, les variances et les écart-types se correspondent par le seul changement d'échelle a pris respectivement au carré et en valeur absolue :

$$\sigma_y^2 = a^2 \sigma_x^2 \text{ et } \sigma_y = |a| \sigma_x$$

4. **L'écart absolu moyen à la moyenne** est la moyenne arithmétique de valeurs absolues des écarts à la moyenne arithmétique :

Les données brutes	Les données agrégées	Les données regroupées en classe
$e_m = \frac{1}{N} \sum_{i=1}^N x_i - \bar{x} $	$e_m = \frac{1}{N} \sum_{i=1}^k n_i x_i - \bar{x} $ $\sum_{i=1}^k f_i x_i - \bar{x} $	$e_m = \frac{1}{N} \sum_{i=1}^k n_i c_i - \bar{x} $ $\sum_{i=1}^k f_i c_i - \bar{x} $

C. Paramètres de dispersion relative

Ces paramètres permettent de comparer les distributions statistiques de plusieurs sous-ensembles d'une même population, ou de faire des comparaisons dans le temps ou dans l'espace

1. Le **coefficient de variation** $C_V = \frac{\sigma}{\bar{x}}$ est défini pour des variables *positives*
2. L'**interquantile relatif** $\frac{x_p - x_{1-p}}{M_{\hat{e}}}$
 L'**interquartile relatif** $\frac{Q_3 - Q_1}{Q_2}$
 L'**interdécile relatif** $\frac{D_9 - D_1}{D_5}$
 L'**intercentile relatif** $\frac{C_{99} - C_1}{C_{50}} \dots \dots \text{ect}$

D. Paramètres de forme

Ici, interviennent les statistiques de moments centrés d'ordre r qui est définie par :


Les données brutes	Les données agrégées	Les données regroupées en classe
$\mu_r = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x})^r$	$\begin{aligned} \mu_r &= \frac{1}{N} \sum_{i=1}^K n_i (x_i - \bar{x})^r \\ &= \sum_{i=1}^K f_i (x_i - \bar{x})^r \end{aligned}$	$\begin{aligned} \mu_r &= \frac{1}{N} \sum_{i=1}^K n_i (c_i - \bar{x})^r \\ &= \sum_{i=1}^K f_i (c_i - \bar{x})^r \end{aligned}$

1. Coefficients d'asymétrie

Les coefficients d'asymétrie sont basés sur l'utilisation de moment d'ordre 3 d'une part, et sur les positions de quantiles par rapport à la médiane d'autre part. Nous ne retiendrons ici que deux coefficients.

➤ Coefficient de Fisher

Ce coefficient est défini par : $\gamma_1 = \frac{\mu_3}{\sigma^3}$.



➤ Coefficient de Yule

Ce coefficient est défini par $C_y = \frac{Q_3 + Q_1 - 2Q_2}{Q_3 - Q_1}$. Il est aussi défini par : $C_y = \frac{D_9 + D_1 - 2D_5}{D_9 - D_1}$ ou

$$C_y = \frac{C_{99} + C_1 - 2C_{50}}{C_{99} - C_1} \dots \dots \text{ect.}$$


Ces coefficients d'asymétrie, sont *nuls* pour une distribution *symétrique*, négatif pour une distribution unimodale étalée à gauche, positif pour une distribution unimodale étalée à droite.

2. Coefficients d'aplatissement

Les coefficients d'aplatissement mesurent l'aplatissement d'une distribution ou l'homogénéité de la population. Nous ne retiendrons ici qu'un seul coefficient. Il s'agit du coefficient d'aplatissement de **Fisher**

$$\gamma_2 = \frac{\mu_4}{\sigma^4} - 3$$

Ce coefficient est *nul* pour une *distribution normale* positive ou négative selon que la distribution est plus ou moins pointue que la distribution normale de même moyenne et de même écart-type.



E. Paramètres de concentration

La notion de *concentration* a été introduite à propos des distributions de salaires et de revenus. Cette notion est apparentée à celle de dispersion puisqu'elle concerne l'intensité du groupement des données. Elle ne s'applique qu'à des variables *continues* à valeurs *positives*, et pour des ensembles statistiques dont « l'addition des caractères possède une signification.

1. Indicateur de concentration

La **Médiale** est un paramètre qui s'apparente à la médiane, mais appliqué à une série différente. En effet, alors que la médiane s'applique aux valeurs de la variable ($x_i; i = 1 \text{ à } k$), la médiale s'applique aux valeurs de la variable ($n_i c_i; i = 1 \text{ à } k$) composée des centres des classes multipliés par leurs effectifs respectifs. Sa méthode de calcul est similaire à celle de médiane. La valeur de la médiale est donnée donc par la formule suivante :

$$M_l = e_{i-1} + \frac{\frac{\sum_{l=1}^k n_l c_l}{2} - (n_{i-1} \cdot c_{i-1})}{n_i c_i} \cdot a_i.$$

Où : e_{i-1} = Borne inférieure de la classe médiale.

$(n_{i-1} c_{i-1}) \nearrow$ = Effectif cumulé croissant de classe précédente la classe médiale.

a_i = Amplitude de la classe médiale.

L'indicateur de concentration I_c , est utilisé pour mesurer le niveau de concentration de la série statistique. Il est donné par la formule :


$$I_c = \frac{\Delta M}{E} \cdot E = \text{Etendu de la série de distribution et } \Delta M = M_l - M_g \cdot$$

2. Indice de Gini

Pour construire la courbe de concentration, on considère la distribution d'une variable continue dont l'intervalle de variation est partagé en k classes dont les bornes supérieures sont notées dans l'ordre : $e_1, \dots, e_k$. On calcule pour chaque classe ($i = 1$ à k) :

- La fréquence cumulée F_i qui représente la proportion des individus dont la valeur de la variable est inférieure à e_i .
- La proportion cumulée R_i qui représente la part des « volumes » dont la valeur est inférieure à e_i , dans le « volume total ». $R_i = \frac{\sum_{j=1}^i n_j c_j}{\sum_{j=1}^k n_j c_j}$.

Sur un diagramme cartésien, on représente les k points de coordonnées (F_i^+, R_i) . Ces points s'inscrivent dans un carré OABC dont la longueur des côtés est égale à 1 (ou 100 si les proportions sont exprimées en pourcentage). La courbe qui joint les points successifs est la **courbe de concentration** ou *courbe de Lorenz*. L'aire de concentration est l'aire située entre la première bissectrice et la courbe de Lorenz.



L'indice de l'inégalité de Gini I_G est égal au double de l'aire de concentration. Il est compris entre 0 et 1. Il est égal à 0 dans le cas d'une égalité parfaite et à 1 dans le cas d'une inégalité parfaite. Il est donné par la formule suivante :

$$I_G = 1 - \sum_{i=1}^k f_i (R_i + R_{i-1}), \text{ avec } R_0 = 0.$$

Chapitre 3 : Indices statistiques

Exemple 1. Entre janvier 2006 et janvier 2010, l'évolution des prix et du nombre d'exemplaires de journaux vendus en un mois par une société de presse éditant trois journaux mensuels A, B et C a été la suivante :

	janvier 2006		janvier 2010	
	Prix (en euros)	Quantité	Prix (en euros)	Quantité
Journal A	2,5	8 000	3	6 500
Journal B	4	4 000	4,5	5 000
Journal C	5	2 000	6	1 500

I. Indices élémentaires

On appelle indice élémentaire de la grandeur simple x à la date (ou au lieu) t dite date courante par rapport à la date 0, dite date (lieu) de référence le rapport : $I_{t/0} = \frac{x_t}{x_0}$. Les indices de date sont appelés indices temporels et ceux des lieux sont appelés spatiaux.

Il est d'habitude de multiplier les indices par cent pour éviter de manipuler trop de chiffre après la virgule.

Exemple 2 : La population française était au nombre de 53 731 000 habitants le 1/1/80 et au nombre de 56 577 000 habitants le 1/1/90 et au nombre de 58 749 000 d'habitants au 1/1/00. Ainsi

$$100 * I_{90/80} = 100 * \frac{56577000}{53731000} = 105,3$$

$$100 * I_{00/80} = 100 * \frac{58749000}{53731000} = 109,3$$

$$100 * I_{00/90} = 100 * \frac{58749000}{56577000} = 103,8$$

La population française a augmenté de 5,3% sur la période 80 à 90, de 3,8% sur la période 90 à 00 et de 9,3% sur toute la période 80 à 00.

On remarque que $I_{00/80} = I_{00/90} * I_{90/80}$

Propriétés

- Circularité : $I_{t/0} = I_{t/t'} * I_{t'/0}$. Cette formule permet de changer de base en passant de la date de référence 0 à la date de référence t' . On a souvent besoin de mesurer l'évolution entre des dates différentes de la date de référence. Elle se généralise à

$$I_{t/0} = I_{t/t-1} * I_{t-1/t-2} * \dots * I_{1/0}$$

- Réversibilité : $I_{t/0} = \frac{1}{I_{0/t}}$. Cette propriété trouve son intérêt dans la comparaison spéciale car le lieu de référence est arbitraire.
- Multiplication : si une quantité $z = x \times y$ alors $I_{t/0}(z) = I_{t/0}(x) \times I_{t/0}(y)$.

II. Les indices synthétiques

Les indices élémentaires retracent l'évolution d'une seule grandeur parfaitement définie et homogène. Mais souvent on désire suivre les variations de grandeurs complexes telles que les prix des produits de consommation, la production industrielle. Ces grandeurs complexes sont composées d'un nombre de grandeurs simples dont l'évolution de chacune est décrite par un indice élémentaire.

On appelle indice synthétique, un indice faisant intervenir dans son calcul plusieurs grandeurs intéressant un même phénomène économique. On l'obtient en calculant une moyenne pondérée d'indices élémentaires.

Indices de Laspeyres et Paasche

Soient p_t^i les prix unitaires de à la date t des q_t^i quantités non sommables. La valeurs de ces biens est donnée par $V_t = \sum_i p_t^i q_t^i$. On peut définir l'indice élémentaire de valeur

$$I_{t/0}(V) = \frac{V_t}{V_0} = \frac{\sum_i p_t^i q_t^i}{\sum_i p_0^i q_0^i}$$

Pour séparer les deux influences et chiffrer les variations « moyennes » des prix et celles des quantités, il est nécessaire de recourir à des indices synthétiques.

On définit les indices de Laspeyres des prix et des quantités par

$$L_{t/0}(p) = \frac{\sum_i p_t^i q_0^i}{\sum_i p_0^i q_0^i} = \sum_i \frac{p_0^i q_0^i}{\sum_i p_0^i q_0^i} \frac{p_t^i}{p_0^i} = \sum_i k_0^i I_{t/0}(p_i)$$

$$L_{t/0}(q) = \frac{\sum_i p_0^i q_t^i}{\sum_i p_0^i q_0^i} = \sum_i \frac{p_0^i q_0^i}{\sum_i p_0^i q_0^i} \frac{q_t^i}{q_0^i} = \sum_i k_0^i I_{t/0}(q_i)$$

Ici k_0^i s'interprète, comme le coefficient budgétaire du produit i, c'est-à-dire la part de dépense totale qui lui est consacrée, à la période de base. On les appelle également les pondérations qui sont calculées une fois à la date de base et on les utilise pour calculer les indices pour les dates postérieures.

Les pondérations suivantes résultent d'une enquête budget-consommation réalisée auprès des ménages à revenus moyens en Mauritanie. Il date de 1985 et servent à calculer le IPC (indice des prix à la consommation) dont la base de référence est justement l'année 1985.

Alimentation:		52,00
céréales	9,00	
légumes	3,30	
fruits	0,60	
viandes-poissons	13,80	
condiments	3,80	
laits, matières grasses	11,00	
sucres, excitants, boissons	10,50	
Habillement :		14,60
tissu	10,60	
chaussures	4,00	
Habitation :		25,30
matériaux de construc.	14,80	
appareils ménagers	1,41	
entretien	1,30	
équipement	2,19	
combustible, eau, élec.	5,60	
Divers :		8,10
santé-hygiène	2,30	
domesticité	3,00	
communication	1,98	
loisirs, instruction	0,82	
T O T A L		100,00

Source : ONS (Office National des Statistiques)

On remarque que $\sum_i k_0^i = 1$. Donc les indices de Laspeyres des prix et des quantités sont les moyennes arithmétiques, pondérées par les coefficients budgétaires à la date 0, des indices élémentaires.

On définit également les indices de Paasche des prix et des quantités par

$$\Pi_{t/0}(p) = \frac{\sum_i p_t^i q_t^i}{\sum_i p_0^i q_t^i} = \frac{1}{\sum_i \frac{p_t^i q_t^i}{\frac{p_0^i}{k_t^i} p_t^i}} = \sum_i \frac{1}{k_t^i \frac{1}{I_{t/0}(p_i)}}$$

$$\Pi_{t/0}(q) = \frac{\sum_i p_t^i q_t^i}{\sum_i p_t^i q_0^i} = \frac{1}{\sum_i \frac{p_t^i q_t^i}{\frac{q_0^i}{k_t^i} q_t^i}} = \sum_i \frac{1}{k_t^i \frac{1}{I_{t/0}(q_i)}}$$

Donc les indices de Paasche des prix et des quantités sont les moyennes harmoniques, pondérées par les coefficients budgétaires à la date t, des indices élémentaires.

Relation entre les deux indices

On a

$$I_{t/0}(V) = L_{t/0}(p) \times \Pi_{t/0}(q) = L_{t/0}(q) \times \Pi_{t/0}(p)$$

La moyenne harmonique est inférieure à la moyenne arithmétique, mais on ne peut comparer les indices de Laspeyres et de Paasche que si les coefficients de pondération sont les mêmes. Mais souvent l'indice de Paasche est plus petit que l'indice de Laspeyres.

Conformément à la loi économique de l'offre et de la demande, les consommateurs ont tendance à acheter moins lorsque les prix sont élevés et à acheter davantage quand les prix baissent. Supposons que l'ait dans un contexte inflationniste, le numérateur l'indice de Laspeyres est un peu plus fort qu'il ne devrait l'être, car, conformément à la loi de l'offre et de la demande, les consommateurs ont tendance à acheter moins de biens de prix élevés et davantage de biens bon marché. Il en résulte que le coût total sera inférieur à celui donné par $\sum_i p_t^i q_0^i$. Ainsi, l'indice de Laspeyres a tendance à surévaluer une hausse. A l'inverse, l'indice de Paasche a tendance à sous-évaluer une hausse.

On définit l'indices de Fisher par

$$F_{t/0}(p) = \sqrt{L_{t/0}(p) \times \Pi_{t/0}(p)} \text{ et } F_{t/0}(q) = \sqrt{L_{t/0}(q) \times \Pi_{t/0}(q)}$$

On peut facilement vérifier que $I_{t/0}(V) = F_{t/0}(p) \times F_{t/0}(q)$

Propriétés

- Circularité : Les trois indices ne sont pas circulaires
- Réversibilité : Les indices de Laspeyres et Paasche ne sont pas réversibles mais on a $L_{t/0}(p) = \frac{1}{\Pi_{0/t}(p)}$ donc l'indice de Fisher est réversible.
- Multiplication : Les indices de Laspeyres et Paasche ne sont pas multiplicatifs mais on a $I_{t/0}(V) = L_{t/0}(p) \times \Pi_{t/0}(q) = L_{t/0}(q) \times \Pi_{t/0}(p)$.
D'où l'indice de Fisher est multiplicatif.
- Agrégation : Les indices de Laspeyres et de Paasche ont des structures de moyenne. Il en résulte que l'indice de Laspeyres (resp. de Paasche) d'un ensemble peut s'obtenir à partir des indices des groupes formant cet ensemble en leur appliquant la formule de Laspeyres.

