



Statistique descriptive : Statistique descriptive uni-variée (a une variable) : Analyse et synthèse, NUMERIQUE et GRAPHIQUE, d'un ensemble de données.

Chapitre1 : Introduction: vocabulaires statistiques

1)- Définitions:

* **statistique** : la statistique est ensemble des méthodes qui servent à organiser les épreuves fournissant des observations, à analyser celles-ci et à interpréter les résultats.

L'analyse statistique se subdivise en deux parties

Statistique descriptive : a pour but de décrire c-à-d de résumer ou représenter les données.

Questions typiques :

*Représentation graphique

*Paramètres de position, de dispersion, de relation.

Statistique différentielle : l'ensemble des méthodes permettant de formuler un jugement ; Elle nécessite des outils mathématiques plus pointus (théorie des probabilités).

2)- Notions de bases :

***POPULATION** : La collection d'objets ou de personnes étudiées (élèves, habitants, voitures...).

***INDIVIDU** : élément de la population étudiée. Exemple :(un élève, un habitant, une voiture,...).

***ECHANTILLON** : partie de la population étudiée. Exemple : Nombre d'individus dans un échantillon Noté n est appelé taille de l'échantillon.

***VARIABLE (CARACTERE)** : propriété commune aux individus de la population, que l'on veut étudier.

Un caractère peut être :

a)-qualitatif : on ne peut associer ni valeur numérique ni un ordre naturel (type de voiture, couleur des cheveux,...).



Quantitatif : peut prendre des valeurs numériques (poids, longueur) un caractère quantitatif peut être :

***Continue** : peut prendre toutes les valeurs numériques d'un intervalle déterminé (Taille, poids...).

***Discontinue (discrète)** : ne peut prendre que des valeurs numériques isolées (nombre de pièces d'habitations, nombre de fruits endommagés...).

***MODALITE** : l'une des formes particulières d'un caractère. La couleur des yeux est un caractère, ses modalités sont : bleu, vert, marron,...

***EFFECTIF OU FREQUENCE ABSOLUE (noté n_i)** : nombre d'apparitions de la valeur associé à un caractère dans un échantillon.

***FREQUENCE RELATIVE (noté f_i)** $f_i = \frac{n_i}{n}$ SERIE STATISTIQUE l'ensemble des valeurs du caractère avec en regard, les fréquences absolue ou relative correspondantes.

*On appelle **LES STATISTIQUES (au pluriel)** des collections de nombres présentées sous forme de tableaux ou de graphique groupant des observations relatives à un phénomène considéré.

Exemple 1 :

Nombre d'enfant	0	1	2	3	4	5	TOTAL
Nombre de famille ou effectif : n_i	16	18	14	11	3	2	64
Fréquence relative : f_i	0,250	0,281	0,218	0,172	0,047	0,031	1

Population étudié : les familles

L'échantillon sur lequel porte l'étude : familles d'un immeuble ; $n=64$.

Le caractère étudié est le nombre d'enfants par famille. C'est un caractère quantitatif discret.



3) Traitement d'une série statistique :

***Série ordonnée :** les valeurs obtenues peuvent être rangées par ordre de grandeur par

Exemple croissante. On obtient une série statistique ordonnée.

***Etendue de la série :** la différence entre les deux valeurs extrêmes est appelée étendue de la série.

***Classe :** quand le caractère étudié est quantitatif continu, la série statistique est répartie en classes ou intervalles semi ouverts. Le nombre de classes, k est calculé par l'une des deux formules :

La règle de Sturge

$$k=1+3.3\log(n)$$

La règle de Yule $k=2.5(n)^{1/4}$

Centre de classe : on appelle centre de classe, la demi-somme des valeurs extrêmes de la classe. On note C_i le centre de la classe.

***Effectif cumulé :** la somme des effectifs des i première classe est appelé effectif cumulé de la i ème classe on le note **ni cum** .

***Fréquence cumulée :** le rapport $ni\ cum / N$ est appelé fréquence cumulé de la i ème classe (N est la taille de l'échantillon).

Exemple2 :

Le taux de glucose sanguin (glycémie) déterminé chez 32 sujets est donné ci-dessous en g/l

Série ordonnée :

0,85 0,95 1,00 1,06 1,11 1,19

0,87 0,97 1,01 1,07 1,13 1,20

0,90 0,97 1,03 1,08 1,14

0,93 0,98 1,03 1,08 1,14

0,94 0,98 1,03 1,10 1,15



0,99 1,04 1,10 1,17

Etendue de la série : $1,20 - 0,85$ en g/l = $0,35$ g/l.

On a $N = 32$ et la formule de Yule donne

$$K = 2.5(32)^{1/4} = 5.94 \approx 6.$$

Classe en g/l	C_i	n_i	f_i	n_i cum
[0, 85 ; 0, 91]		3		
[0, 91 ; 0, 97]		4		
[0, 97 ; 1, 03]		7		
[1,03 ; 1, 09]		8		
[1, 09 ; 1, 15]		6		
[1, 15 ; 1, 21]		4		

Au bas de la colonne n_i , on indique la somme de tous les n_i , $\sum n_i$ qui n'est autre que l'effectif total N de l'échantillon.

De la même façon au bas de la colonne des f_i on indique leur somme $\sum f_i$ qui doit être égal à 1.

La dernière colonne, dite des effectifs cumulés croissants a la signification suivante :

Pour la classe $[0,85 ; 0,91[$: n_i cum = 3, on dit qu'il ya 3 valeurs inférieure à 0,91 g/l.

-Pour la classe $[0,91 ; 0,97[$: n_i cum = $3 + 4 = 7$

il ya 7 valeurs inférieures à 0,97 (3 inférieures à 0,91 et 4 comprises entre 0,91 et 0,97).

-Pour la dernière classe on a donc n_i cum = N .

On appelle fréquence cumulée croissante pour la i ème classe le rapport

$$f_i = n_i \text{ cum} / N$$

On a donc :

Pour la 1^{ère} classe $F_1 = 3/32$.

-Pour la 2^{ème} classe $F_2 = 7/32$.

-Pour la dernière $F_6 = 32/32 = 1$.

On peut de la même façon concevoir des effectifs cumulés décroissants et des fréquences cumulés décroissantes

Chapitre 2 : Les représentations graphiques :

1) Diagramme circulaire :

Un diagramme circulaire est une représentation graphique de données statistiques sous la forme d'un disque partagé en secteurs circulaires. À chaque valeur du caractère étudié correspond un secteur. Les mesures des secteurs sont proportionnelles aux effectifs représentés.


Exemple :

Voici la répartition de 450 collégiens selon la marque de leurs baskets.

Marque	Adidas	Nike	Puma	Autres marques	Total
Effectif	100	70	120	160	450

On veut représenter cette répartition sous la forme d'un diagramme circulaire. À chaque marque correspond un secteur circulaire. Les mesures des secteurs sont proportionnelles aux effectifs représentés, le coefficient de proportionnalité étant ici égal à $360/450$.

On obtient le diagramme suivant :



Remarque :

Un diagramme semi-circulaire se présente sous la forme d'un demi-disque.



Diagramme en barres :

Un diagramme en barres est une représentation graphique de données statistiques à l'aide de rectangles de même largeur.

Les valeurs du caractère étudié sont représentées sur l'axe horizontal, les effectifs sur l'axe vertical.

À chaque valeur correspond une barre. Les hauteurs des barres sont proportionnelles aux effectifs représentés.


Exemple : Voici la répartition de 450 collégiens selon la marque de leurs baskets.

Marque	Adidas	Nike	Puma	Autres marques	Total
Effectif	100	70	120	160	450

On veut représenter cette répartition sous la forme d'un diagramme en barres.

À chaque marque correspond une barre. Les hauteurs des barres sont proportionnelles aux effectifs représentés.

On obtient le diagramme suivant :



3) Diagramme en bâtons :

Un diagramme en bâtons est une représentation graphique de données statistiques à l'aide de segments.

Les valeurs du caractère étudié sont représentées sur l'axe horizontal, les effectifs sur l'axe vertical. À chaque valeur correspond un bâton.

Les hauteurs des bâtons sont proportionnelles aux effectifs représentés.



Exemple :

Voici la répartition de 450 collégiens selon la marque de leurs baskets.

Marque	Adidas	Nike	Puma	Autres marques	Total
Effectif	100	70	120	160	450

On veut représenter cette répartition sous la forme d'un diagramme en bâtons. À chaque marque correspond un bâton. Les hauteurs des bâtons sont proportionnelles aux effectifs représentés.

On obtient le diagramme suivant :





Diagramme statistique

Un diagramme statistique est une représentation graphique de **données statistiques**.


On distingue : les diagrammes circulaires, les diagrammes en barres, les diagrammes en bâtons.

Exemple :

Nombre de jours de pluie à Brest



Livres empruntés à la section jeunesse
de la bibliothèque de Robinson



4) L'histogramme: est adapté pour représenter des caractères statistiques dont les valeurs sont réparties en classes, c'est-à-dire que les valeurs sont réparties dans des intervalles.

Il est très utilisé pour représenter les effectifs ou les fréquences de ces classes.

Pour le construire : On met généralement le caractère étudié en abscisse et les effectifs correspondants en ordonnée. Il faut bien choisir les unités pour que le diagramme soit le plus lisible possible.

Exemple


Dans une entreprise, pour être vendues, les pommes de terre sont triées selon leur calibre. On a regroupé les résultats dans le tableau suivant.

Calibre en mm	[60 ; 65[	[65 ; 70[	[70 ; 75[	[75 ; 80[
Quantité en kg	105	156	145	98

Sur l'axe des abscisses, on peut choisir 2 cm pour 5 mm et commencer à 55 mm.

Sur l'axe des ordonnées, on peut choisir 1 cm pour 10 kg.

On obtient l'histogramme correspondant.



Répartition de la quantité de pommes de terre en fonction de leur calibre

Pour le lire : Généralement, le caractère étudié est en abscisse et l'effectif correspondant en ordonnée. Dans ce cas, la hauteur de chaque barre est proportionnelle à l'effectif.

Si le caractère étudié est en ordonnée et l'effectif en abscisse, c'est la longueur de chaque barre (de gauche à droite) qui est proportionnelle à l'effectif.

Exemple :

Dans l'histogramme ci-dessus, le caractère étudié est le calibre de pommes de terre (en abscisse) et l'effectif correspondant est en ordonnée.

La barre verte signifie qu'environ 145 kg de pommes de terre ont un calibre compris entre 70 et 75 mm.

5) Le diagramme en boîte : Le **diagramme en boîte**, appelé également **boîte à moustaches**, est en quelque sorte une représentation symbolique comportant plusieurs paramètres de la série. Sa définition peut varier mais on y trouvera toujours :

- la médiane Me ;
- les quartiles Q_1 et Q_3 ;
- les minimales et maximales du caractère (Min et Max).

Il est possible d'y trouver également les déciles D_1 et D_9 (et même des centiles...).

Pour le construire et pour le lire

Il se construit de la manière suivante :



En réalité, sur l'axe gradué qui est sous la boîte ne doivent figurer que les valeurs des graduations.

Le diagramme en boîte permet de visualiser les quatre quarts de la série :

- 25 % de la population a une valeur de caractère inférieure à Q_1 ;
- 50 % de la population a une valeur de caractère inférieure à Me ;
- 75 % de la population a une valeur de caractère inférieure à Q_3 ;
- 100 % de la population a une valeur de caractère inférieure à Max.

Le diagramme indique aussi l'étendue de la série (la longueur du diagramme) et l'écart interquartile (la longueur de la boîte).

On a ainsi 50 % de la population « dans la boîte ».



Exemple:
On considère la série statistique de 50 valeurs présentées dans le tableau ci-dessous. On a pris soin de les ordonner de la plus petite à la plus grande.

5	15	19	21	29
7	16	19	21	30
11	16	19	23	33
14	16	19	24	33
15	16	19	24	33
15	16	20	25	33
15	16	20	25	33
15	17	20	26	34
15	18	20	27	34
15	18	21	28	35

La plus petite valeur est $\text{Min} = 5$, la plus grande $\text{Max} = 35$.

Il y a 50 valeurs, la médiane est la moyenne de la 25^e et de la 26^e :

$$\text{Me} = (19 + 20) \div 2 = 19,5.$$

Pour Q_1 : 25 % de 50, cela fait 12,5. Il faut laisser au moins 25 % en dessous de Q_1 , on prend la 13^e valeur : $Q_1 = 16$.

Pour Q_3 : 75 % de 50, cela fait 37,5. Il faut laisser 75 % au moins en dessous de Q_3 , on prend la 38^e valeur: $Q_3 = 26$.

L'écart interquartile est donc égal à $Q_3 - Q_1 = 26 - 16 = 10$.

Voici une représentation de la boîte à moustache de cette série.

