

Statistique Descriptive

Chapitre1 : Introduction: vocabulaires statistiques

1)- Définitions:

* **statistique** : la statistique est un ensemble des méthodes qui servent à organiser les épreuves fournissant des observations, à analyser celles-ci et à interpréter les résultats.

2)- Notions de bases :

* **POPULATION** : La collection d'objets ou de personnes étudiées (élèves, habitants, voitures...).

* **INDIVIDU** : élément de la population étudiée. Exemple :(un élève, un habitant, une voiture,...).

* **ECHANTILLON** : partie de la population étudiée. Exemple : Nombre d'individus dans un échantillon Noté n est appelé taille de l'échantillon.

* **VARIABLE (CARACTERE)** : propriété commune aux individus de la population, que l'on veut étudier ; Un caractère peut être :

a)-qualitatif : un caractère est dit qualitatif si ses modalités ne sont pas mesurable. Dans ce cas, les modalités sont aussi appelées catégories. Si les modalités du caractère qualitatif ne sont pas naturellement ordonnées on dira qu'il est nominal, par contre si les modalités sont organisées selon un ordre hiérarchique on dira qu'il est ordinal.

Le caractère "couleur des yeux" est nominal alors que le caractère " mention du Bac" est ordinal.

b)- quantitatif : peut prendre des valeurs numérique (poids, longueur) un caractère quantitatif peut être :

* **Continue** : peut prendre toutes les valeurs numériques d'un intervalle déterminé (Taille, poids...).

* **Discontinue (discrète)** : ne peut prendre que des valeurs numériques isolées (nombre de pièces d'habitations, nombre de fruits endommagés...).

* **MODALITE** : l'une des formes particulières d'un caractère. La couleur des yeux est un caractère, ses modalités sont : bleu, vert, marron,...

* **EFFECTIF OU FREQUENCE ABSOLUE (noté n_i)** : nombre d'apparitions de la valeur associé à un caractère dans un échantillon.

***FREQUENCE RELATIVE (noté f_i) $f_i =$** ou fréquence d'une valeur est le quotient de l'effectif de cette valeur par l'effectif de la population (effectif total) ; c'est un nombre compris entre 0 et 1 ; la somme des fréquences est toujours égale à 1.

*On appelle **LES STATISTIQUES (au pluriel)** des collections de nombres présentées sous forme de tableaux ou de graphique groupant des observations relatives à un phénomène considéré.

Exemple 1 :

Nombre d'enfant	0	1	2	3	4	5	TOTAL
Nombre de famille ou effectif : n_i	16	18	14	11	3	2	64
Fréquence relative : f_i	0,250	0,281	0,218	0,172	0,047	0,031	1

Population étudié : les familles

L'échantillon sur lequel porte l'étude : familles d'un immeuble ; $n=64$.

Le caractère étudié est le nombre d'enfants par famille. C'est un caractère quantitatif discret.

3) Traitement d'une série statistique :

***Série ordonnée :** les valeurs obtenues peuvent être rangées par ordre de grandeur par

Exemple croissante. On obtient une série statistique ordonnée.

***Etendue de la série :** la différence entre les deux valeurs extrêmes est appelée étendue de la série.

***Classe :** quand le caractère étudié est quantitatif continu, la série statistique est répartie en classes ou intervalles semi ouverts.

***Centre de classe :** on appelle centre de classe, la demi-somme des valeurs extrêmes de la classe. On note C_i le centre de la classe.

***Effectif cumulé :** la somme des effectifs des i première classe est appelé effectif cumulé de la ième classe on le note **ni cum** .

***Fréquence cumulée :** le rapport **ni cum**/**N** est appelé fréquence cumulé de la ième classe (N est la taille de l'échantillon).

On peut de la même façon concevoir des effectifs cumulés décroissants et des fréquences cumulés décroissantes

Chapitre 2 : Les représentations graphiques :


1) Diagramme circulaire : Un diagramme circulaire est une représentation graphique de données statistiques sous la forme d'un disque partagé en secteurs circulaires. À chaque valeur du caractère étudié correspond un secteur. Les mesures des secteurs sont proportionnelles aux effectifs représentés.

Exemple : Voici la répartition de 450 collégiens selon la marque de leurs baskets.

Marque	Adidas	Nike	Puma	Autres marques	Total
Effectif	100	70	120	160	450

On veut représenter cette répartition sous la forme d'un diagramme circulaire. À chaque marque correspond un secteur circulaire. Les mesures des secteurs sont proportionnelles aux effectifs représentés, le coefficient de proportionnalité étant ici égal à $360/450$.

On obtient le diagramme suivant :



Remarque :

Un diagramme semi-circulaire se présente sous la forme d'un demi-disque.

Diagramme en barres :

Un diagramme en barres est une représentation graphique de données statistiques à l'aide de rectangles de même largeur.

Les valeurs du caractère étudié sont représentées sur l'axe horizontal, les effectifs sur l'axe vertical.

À chaque valeur correspond une barre. Les hauteurs des barres sont proportionnelles aux effectifs représentés.


Exemple : Voici la répartition de 450 collégiens selon la marque de leurs baskets.

Marque	Adidas	Nike	Puma	Autres marques	Total
Effectif	100	70	120	160	450

On veut représenter cette répartition sous la forme d'un diagramme en barres.

À chaque marque correspond une barre. Les hauteurs des barres sont proportionnelles aux effectifs représentés.

On obtient le diagramme suivant :



2) Diagramme en bâtons :

Un diagramme en bâtons est une représentation graphique de données statistiques à l'aide de segments.

Les valeurs du caractère étudié sont représentées sur l'axe horizontal, les effectifs sur l'axe vertical. À chaque valeur correspond un bâton.

Les hauteurs des bâtons sont proportionnelles aux effectifs représentés.


Exemple :

Voici la répartition de 450 collégiens selon la marque de leurs baskets.

Marque	Adidas	Nike	Puma	Autres marques	Total
Effectif	100	70	120	160	450

On veut représenter cette répartition sous la forme d'un diagramme en bâtons. À chaque marque correspond un bâton. Les hauteurs des bâtons sont proportionnelles aux effectifs représentés.

On obtient le diagramme suivant :



Le Diagramme statistique :

Un diagramme statistique est une représentation graphique de **données statistiques**.

On distingue : les diagrammes circulaires, les diagrammes en barres, les diagrammes en bâtons.

3) L’histogramme: est adapté pour représenter des caractères statistiques dont les valeurs sont réparties en classes, c’est-à-dire que les valeurs sont réparties dans des intervalles.

Il est très utilisé pour représenter les effectifs ou les fréquences de ces classes.

Pour le construire : On met généralement le caractère étudié en abscisse et les effectifs correspondants en ordonnée. Il faut bien choisir les unités pour que le diagramme soit le plus lisible possible.

Exemple


Dans une entreprise, pour être vendues, les pommes de terre sont triées selon leur calibre. On a regroupé les résultats dans le tableau suivant.

Calibre en mm	[60 ; 65[	[65 ; 70[	[70 ; 75[	[75 ; 80[
Quantité en kg	105	156	145	98

Sur l’axe des abscisses, on peut choisir 2 cm pour 5 mm et commencer à 55 mm.

Sur l’axe des ordonnées, on peut choisir 1 cm pour 10 kg.

On obtient l’histogramme correspondant.



Répartition de la quantité de pommes de terre en fonction de leur calibre

Pour le lire : Généralement, le caractère étudié est en abscisse et l'effectif correspondant en ordonnée. Dans ce cas, la hauteur de chaque barre est proportionnelle à l'effectif.

Si le caractère étudié est en ordonnée et l'effectif en abscisse, c'est la longueur de chaque barre (de gauche à droite) qui est proportionnelle à l'effectif.

Exemple :

Dans l'histogramme ci-dessus, le caractère étudié est le calibre de pommes de terre (en abscisse) et l'effectif correspondant est en ordonnée.

La barre verte signifie qu'environ 145 kg de pommes de terre ont un calibre compris entre 70 et 75 mm.

Chapitre 3 : LES PARAMETRES DE POSITION.

1. Le Mode

Définition : En statistique, le mode désigne le nombre qui apparaît le plus souvent dans un ensemble de nombres le mode, Il correspond au sommet de la distribution, graphiquement, il est dénoté par M_O . Autrement dit le mode (ou valeur modale), est la valeur que la variable statistique prend le plus souvent (la valeur qui a le plus grand effectif).

Le mode peut être calculé pour les caractères qualitatifs comme pour les caractères quantitatifs.

Dans ce cours on va apprendre comment calculer le mode dans le cas d'une variable statistique qualitative, quantitative discrète et quantitative continue. Aussi on va apprendre comment trouver le mode par la méthode mathématique.

Par exemple, si un ensemble de nombres contient les chiffres suivants :

1, 1, 3, 5, 6, 6, 7, 7, 7, 8, le mode sera 7, car il apparaît le plus souvent parmi tous les nombres de l'ensemble.

Calculer le mode dans le cas d'une variable qualitative

Le mode est la modalité correspondante à l'effectif le plus important.

EXEMPLE : Répartition des salariés de l'entreprise X selon le contrat de travail :

CSP	Cadres supérieurs	Contremaitres	Employer	Ouvriers spécialisés	Autres catégories
Effectifs des salariés	10	5	20	40	5

Le mode de ce caractère est la modalité « ouvriers spécialisés »


Calculer le mode dans le cas d'une variable quantitative discrète

Le mode est la modalité correspondante à l'effectif le plus important.

x_i	n_i	N_i	$f_i(\%)$	$F_i(\%)$
5	3	3	6	6
6	5	8	10	16
7	3	11	6	22
8	4	15	8	30
9	2	17	4	34
$M_0=10$	8	25	16	50
11	5	30	10	60
$M_0=12$	8	38	16	76
13	3	41	6	82
14	5	46	10	92
15	3	49	6	98
16	1	50	2	100
Total	50	-	100	-

A partir du [tableau statistique](#) ci-dessus (ou de son diagramme en bâtons correspondant), on a deux modes :

$M_0 = x_6 = 10$ et $M_0 = x_8 = 12$.



La classe modale dans le cas d'une variable quantitative continue

Dans le cas de variable continue, on parle plutôt de classe modale ; c'est la classe qui a la plus grande densité d'effectif (ou la plus grande densité de fréquence).

Si les classes sont toutes de même amplitude, la classe modale est la classe d'effectif le plus élevé ou de fréquence la plus élevée.

Si les classes ne sont pas toutes de même amplitude, la classe modale est la classe dont l'effectif corrigé ou la fréquence corrigée est maximum.

EXEMPLE 1 :

On considère la distribution statistique d'une population d'étudiants selon leur taille (en cm):

Taille (cm)	<160	[160;170[	[170;180[	[180;190[	≥ 190	total
effectif	6	7	8	2	1	24
Fréquences en %	25	29,1	33,3	8,3	4,3	100

L'effectif ou la fréquence les plus élevés montrent que le classe modale est [170;180[

Soit la distribution d'une population des étudiants répartis suivant leur poids (en kg) :

L'effectif ou la fréquence les plus élevés montrent que le classe modale est [170;180[

Soit la distribution d'une population des étudiants répartis suivant leur poids (en kg) :

Poids (en kg)	Effectif (n_i)	Fréquence (f_i) en %	Amplitude (a_i)	fréquence corrigée $f_{ico}=f_i/a_i$
<55	2	8,33	5	1,67
[55;60[	3	12,5	5	2,5
[60;70[	4	16,67	10	1,67
[70;75[	5	20,83	5	4,17
[75;85[	6	25	10	2,5
≥85	4	16,67	10	1,67
Total	24	100		

La classe modale, à laquelle est associée la fréquence corrigée la plus grande, est la classe [70; 75[

Détermination du Mode : On peut également déterminer la valeur du mode, à l'intérieur de la classe modale [2.09; 2.24 [.

$[b_{i-1}, b_i[$	n_i	N_i	f_i	F_i
$[1.94, 2.09[$	8	8	0.18	0.18
classe modale= $[2.09, 2.24[$	10	18	0.23	0.41
$[2.24, 2.39[$	9	27	0.20	0.61
$[2.39, 2.54[$	8	35	0.18	0.79
$[2.54, 2.69[$	5	40	0.11	0.90
$[2.69, 2.84[$	4	44	0.10	1.00
Total	44	-	1.00	-

On peut calculer le mode pour un caractère quantitatif continu par la formule suivante:

$$M_o = B_i + A_m \frac{\Delta 1}{\Delta 1 + \Delta 2}$$

où

- B_i est la borne inférieure de la classe modale
- A_m est l'amplitude de la classe modale
- $\Delta 1$ = : différence entre la fréquence de la classe modale et la fréquence de la classe précédente
- $\Delta 2$ = : différence entre la fréquence de la classe modale et la fréquence de la classe suivante

On peut aussi dire:

- $\Delta 1$: différence entre l'effectif de la classe modale et l'effectif de la classe précédente
- $\Delta 2$: différence entre l'effectif de la classe modale et l'effectif de la classe suivante

Pour l'exemple précédent nous pourrions déterminer le mode plus précisément par cette formule dans ce même exemple :

On a $\Delta 1 = n_2 - n_1 = 10 - 8 = 2$ et $\Delta 2 = n_2 - n_3 = 10 - 9 = 1$,

donc : $M_0 = B_i + (\Delta 1 / (\Delta 1 + \Delta 2)) A_m = 2.09 + 2/3 \times 0.15 = 2.19$

Exemple 2 : Soit le tableau suivant décrivant la distribution des salaires de 75 employés:

Salaires	[215,235[	[235,255[	[255,275[	[275,295[
Effectifs	4	6	13	22
Fréquences	5,33	8	17,33	29,33
Salaires	[295,315[	[315,335[	[335,355[	[355,375[
Effectifs	15	6	5	4
Fréquences	20	8	6,67	5,33

Le mode calculé par la relation précédente est : $275 + 20((29,33 - 17,33) / ((29,33 - 17,33) + (29,33 - 20))) = 286,25$

2. La Médiane :

Médiane d'une série statistique

1) Définition :

La médiane d'une série ordonnée est la valeur qui partage cette série en deux séries de même effectif.

Il y a donc autant de valeurs supérieures à la médiane que de valeurs inférieures.

Interprétation de la médiane : Au moins 50% des valeurs de la série sont inférieures ou égales à la médiane et au moins 50% des valeurs de la série sont supérieures ou égales à la médiane.

Pour déterminer la médiane d'une série :

- On range les valeurs de la série dans l'ordre croissant
- On cherche la valeur qui partage la série en deux séries de même effectif.

Il y a deux cas, selon que l'effectif total est pair ou impair

2) Détermination de la médiane

a) Cas où l'effectif total est impair

Calculer la médiane de la série suivante :

6 ; 8 ; 10 ; 11 ; 12 ; 13 ; 15 ; 18 ; 20

- La série doit être rangée dans l'ordre croissant :
- Pour avoir deux groupes de même effectif on divise l'effectif total par 2 : $9 \div 2 = 4,5$

6 ; 8 ; 10 ; 11 ; 12 ; 13 ; 15 ; 18 ; 20

4 valeurs 4 valeurs

Valeur de la médiane Dans ce cas la médiane est 12.

b) Cas où l'effectif total est pair

Calculer la médiane de la série suivante :

1 ; 2 ; 5 ; 8 ; 9 ; 12 ; 14 ; 16 ; 17 ; 19

- La série doit être rangée dans l'ordre croissant :
- Pour avoir deux groupes de même effectif : $10 \div 2 = 5$

1 ; 2 ; 5 ; 8 ; 9 ; 12 ; 14 ; 16 ; 17 ; 19

5 valeurs 5 valeurs

Valeur de la médiane

Dans ce cas la médiane est comprise entre 9 et 12

En général on choisit comme médiane la moyenne des deux valeurs centrales :

$$(9 + 12) \div 2 = 10,5$$

La médiane est : 10,5

Médiane d'une série continue

Si la variable est continue (regroupement par intervalle des résultats) le calcul de la médiane se fait autrement :


Notes	Effectifs	Effectifs cumulés
[0 ; 5[	10	10
[5 ; 8[	8	18
[8 ; 12[	12	30
[12 ; 15	11	41
[15 ; 20	9	50
	50	

Utilisons la colonne des effectifs cumulés pour déterminer la médiane : il y a 50 notes, 50 % de l'effectif total c'est 25, la médiane est ici la note correspondant à l'effectif cumulé 25.

D'après la colonne "effectif cumulé" :

- 18 personnes ont moins de 8
- 30 personnes ont moins de 12

La médiane se trouve donc dans l'intervalle $[8;12[$ (appelée classe médiane) on va la déterminer par [interpolation linéaire](#).



Les points A, M, B sont alignés ce qui se traduit par les droites (AM) et (AB) ont même coefficient directeur (ou on utilise le théorème de Thalès dans le triangle bleu) :

$$\frac{Me - 8}{25 - 18} = \frac{12 - 8}{30 - 18}$$

$$\frac{Me - 8}{7} = \frac{4}{12}$$

$$Me - 8 = \frac{4}{12} \times 7$$

$$Me = 8 + \frac{4}{12} \times 7 \approx 10,33$$

La médiane est environ 10,33

50 environ des personnes ont eu moins de 10,33 et 50 % plus de 10,33 .
Les différentes moyennes

LES DIFFERENTES MOYENNES :

- A) **Moyenne arithmétique** : La *moyenne arithmétique* est la **moyenne** « ordinaire », c'est-à-dire la somme des valeurs numériques (de la liste) divisée par le *nombre* de ces valeurs numériques.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

i) Variable quantitative discrète

La moyenne arithmétique pondérée, est égale à la somme des valeurs distinctes de la variable multipliées par leurs effectifs respectifs divisée par la somme des effectifs.

$$\bar{x} = \frac{\sum_i n_i x_i}{\sum_i n_i} = \frac{\sum_i n_i x_i}{N}$$

et comme $f_i = \frac{n_i}{N}$ on a aussi $\bar{x} = \sum_i f_i x_i$

ii) Variable quantitative continue

La moyenne arithmétique notée toujours $\bar{x}$, est égale à la somme des centres des classes de la variable multipliées par leurs effectifs respectifs divisée par la somme des effectifs.

$$\bar{x} = \frac{\sum_i n_i c_i}{\sum_i n_i} = \frac{\sum_i n_i c_i}{N}$$

où c_i est le centre de la classe associée à l'effectif n_i .

et comme $f_i = \frac{n_i}{N}$ on a aussi $\bar{x} = \sum_i f_i c_i$

B) Moyenne quadratique :

- i) **Variable quantitative discrète** : La moyenne quadratique notée x_q , est égale à la somme des carrés des valeurs distinctes de la variable multipliées par leurs effectifs respectifs divisée par la somme des effectifs

$$\bar{x}_q = \frac{\sum_i n_i x_i^2}{\sum_i n_i} = \frac{\sum_i n_i x_i^2}{N} = \sum_i f_i x_i^2 \quad (\text{car } f_i = \frac{n_i}{N})$$

ii) Variable quantitative continue

La moyenne quadratique notée toujours $\bar{x}_q$, est égale à la somme des carrés des centres des classes de la variable multipliées par leurs effectifs respectifs divisée par la somme des effectifs.

$$\bar{x}_q = \frac{\sum_i n_i c_i^2}{\sum_i n_i} = \frac{\sum_i n_i c_i^2}{N} = \sum_i f_i c_i^2 \quad (\text{car } f_i = \frac{n_i}{N})$$

où c_i est le centre de la classe associée à l'effectif n_i .

C) Moyenne géométrique :

i) Variable quantitative discrète

La moyenne géométrique notée $\bar{x}_G$, d'une variable quantitative discrète est donnée par :

$$\bar{x}_G = \sqrt[N]{\prod_i x_i^{n_i}} \quad \text{où } N = \sum_i n_i$$

D) Moyenne harmonique

i) Variable quantitative discrète

C'est l'inverse de la moyenne arithmétique des inverses des valeurs de la variable. On la note $\bar{x}_H$,

$$\bar{x}_H = \frac{N}{\sum_i n_i / x_i}$$

ii) Variable quantitative continue dans ce cas La moyenne harmonique est donnée par :

$$\bar{x}_H = \frac{N}{\sum_i n_i / c_i}$$

Remarque :

$$\bar{x}_H \leq \bar{x}_G \leq \bar{x} \leq \bar{x}_q$$

