

COURS DE STATISTIQUE DESCRIPTIVE BIVARIEE (Statistique - II)

Présenté par :

Moujtaba Ould Taleb Dit Cheiba

ISCAE 2023/2024

S2 – SAE -1

Table des matières

Introduction.....	4
Chapitre 1 : Distributions statistiques à deux variables	5
A. Distribution conjointe.....	5
B. Distributions marginales.....	6
C. Distributions conditionnelles.....	7
D. Dépendance et indépendance statistique	10
Chapitre 2 : Deux variables quantitatives.....	11
A. Caractéristiques d'un couple de deux variables quantitatives	11
1) Moyenne d'une somme de deux variables statistiques.....	11
2) Covariance entre deux variables statistiques	12
3) Coefficient de corrélation linéaire de Pearson	12
B. Ajustement linéaire d'un nuage de point	13
1) Ajustement par la méthode graphique	13
2) Ajustement par la méthode de Mayer	14
3) Ajustement par la méthode des moindres carrés	14
4) Interprétation du coefficient de corrélation linéaire	16
4) Comparaison des deux droites des moindres carrés	19
Chapitre 3 : Une variable qualitative et une variable quantitative	20
A. Variances inter-groupes et intra-groupes.....	20

1) Variance intra-groupes	20
2) Variance inter-groupes	21
3) Décomposition de la variance	21
B. Mesure de la liaison par le rapport de corrélation	21
1) Définition du rapport de corrélation	22
2) Interprétation du rapport de corrélation	22
Chapitre 4 : Deux variables qualitatives	23
A. Coefficient du khi- deux.....	23
B. Le V de Cramer	24

Introduction

Lorsque les observations portent simultanément sur deux caractères, et lorsqu'elles sont trop nombreuses pour qu'on les cite une à une, on les présente sous la forme d'un tableau à double entrée. On définit alors la distribution conjointe, les distributions marginales et les distributions conditionnelles.

L'étude de la distribution de deux variables se poursuit par celle de leur liaison.

L'étude de la liaison entre les variables observées, appelée communément. L'étude des corrélations, dépend de leur nature. On envisagera les trois cas suivants : deux variables quantitatives, une variable quantitative et une variable qualitative, deux variables qualitatives. Lorsque le domaine de variation d'une variable quantitative a été découpé en classes et que les observations sont présentées dans un tableau à double entrée, alors cette variable peut être traitée comme une variable qualitative et dans ce cas, on a plusieurs méthodes pour l'étude de la liaison.

Chapitre 1 : Distributions statistiques à deux variables

A. Distribution conjointe

Désignons par X et Y les deux variables qui peuvent être qualitatives ou quantitatives, et qui peuvent ne pas être de même nature. Les k modalités de X sont désignées par $x_1, \dots, x_i, \dots, x_k$; les l modalités de Y sont désignées par $y_1, \dots, y_j, \dots, y_l$. La $i^{\text{ème}}$ modalité d'une variable désigne le centre de la $i^{\text{ème}}$ classe dans le cas d'une variable quantitative continue.

La répartition des n observations, ou *distribution conjointe*, suivant les modalités de X et Y se présente sous forme d'un tableau à double entrée, Appelée **Tableau de contingence**.

Tableau 1.1 – Tableau de contingence : distribution conjointe de deux variables X et Y .

Modalités de Y Modalités de X	y_1	...	y_j	...	y_l	Total
x_1	n_{11}	...	n_{1j}	...	n_{1l}	$n_{1\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	n_{i1}	...	n_{ij}	...	n_{il}	$n_{i\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_k	n_{k1}	...	n_{kj}	...	n_{kl}	$n_{k\bullet}$
Total	$n_{\bullet 1}$	...	$n_{\bullet j}$	...	$n_{\bullet l}$	n

L'effectif n_{ij} est le nombre d'unités statistiques possédant simultanément la modalité x_i de la variable X et la modalité y_j de la variable Y .

L'effectif $n_{i\bullet}$ est le nombre total d'unités statistiques possédant la modalité x_i de X , quelle que soit la modalité de Y :

$$n_{i\bullet} = \sum_{j=1}^l n_{ij} \quad (n_{i\bullet} \text{ sont appelés les effectifs marginaux de la variable } X)$$

De même, l'effectif $n_{\bullet j}$ est le nombre d'unités statistiques possédant la modalité y_j de Y , quelle que soit la modalité de X :

$$n_{\bullet j} = \sum_{i=1}^k n_{ij} \quad (n_{\bullet j} \text{ sont appelés les effectifs marginaux de la variable } Y)$$

On a évidemment que L'effectif total $n = \sum_{i=1}^k n_{i\bullet} = \sum_{j=1}^l n_{\bullet j} = \sum_{i=1}^k \sum_{j=1}^l n_{ij}$

La distribution conjointe peut aussi être définie par les fréquences : $f_{ij} = \frac{n_{ij}}{n}$.

Tableau 1.2– Exemple de tableau de contingence : distribution des notes de 100 étudiants à une épreuve d'un concours selon leur filière d'origine X et Y .

Classe de notes Y Filière d'origine X	$[0 ; 6[$ 3	$[6 ; 10[$ 8	$[10 ; 14[$ 12	$[14 ; 20[$ 17	Total
Filière A	26	6	4	1	37
Filière B	12	9	3	1	25
Filière C	1	4	5	6	16
Filière D	10	8	3	1	22
Total	49	27	15	9	100

Ainsi par exemple 26 étudiants ont des notes moins de 6 et de la filière A . Aussi, on peut dire qu'il y a 25 étudiants de la filière B et qu'il y a 15 étudiants ayant des notes comprises entre 10 et 14 points.

B. Distributions marginales

Les k couples $(x_i, n_{i\bullet})$ forment la distribution marginale de la variable X .

Les l couples $(y_j, n_{\bullet j})$ forment la distribution marginale de la variable Y .

Les distributions marginales peuvent aussi être données sous forme de fréquences :

$$f_{i\bullet} = \frac{n_{i\bullet}}{n} \text{ et } f_{\bullet j} = \frac{n_{\bullet j}}{n}$$

Disposant d'une distribution conjointe, on peut déduire les distributions marginales qui permettent d'étudier séparément chaque variable en représentant graphiquement sa distribution et s'il s'agit d'une variable quantitative, en calculant ses paramètres de position, de dispersion, de forme...

Tableau 1.3– Exemple de distribution marginale de la variable X : distribution des 100 étudiants selon la filière d'origine

Filière d'origine X	Total
Filière A	37
Filière B	25
Filière C	16
Filière D	22
Total	100

C. Distributions conditionnelles

La distribution de la variable Y , la variable X étant égale à x_i , est appelée distribution conditionnelle de Y pour $X = x_i$:

Tableau 1.4 – Distribution conditionnelle de la variable Y pour $X = x_i$

$Y/X = x_i$	y_1	...	y_j	...	y_l	Total
Effectif	n_{i1}	...	n_{ij}	...	n_{il}	$n_{i\bullet}$

Cette distribution des $n_{i\bullet}$ individus, satisfaisant à la condition $X = x_i$ est présentée sous la forme de fréquences conditionnelles :

$$f_{j/i} = \frac{n_{ij}}{n_{i\bullet}} \text{ avec } \sum_{j=1}^l f_{j/i} = 1$$

$Y/X = x_i$	y_1	...	y_j	...	y_l	Total
Fréquence	$f_{1/i}$	...	$f_{j/i}$	...	$f_{l/i}$	1

La fréquence $f_{j/i}$ se lit « f indice j si i », c'est-à-dire fréquence de y_j si $X = x_i$. Il y a k distributions conditionnelles de Y pour $X = x_i$ ($i = 1, \dots, k$) .

Lorsque la variable Y est quantitative, on peut calculer pour chaque valeur x_i sa moyenne conditionnelle $\bar{y}_i$ et son écart-type conditionnel σ_i^2 :

$$\bar{y}_i = \sum_{j=1}^l f_{j/i} y_j \text{ et } \sigma_i^2 = \sum_{j=1}^l f_{j/i} (y_j - \bar{y}_i)^2$$

Les k modalités de X induisant une partition des observations en k sous-groupes, la moyenne $\bar{y}$ peut s'exprimer comme somme pondérée des k moyennes $\bar{y}_i$:

$$\bar{y} = \sum_{i=1}^k f_{i\bullet} \bar{y}_i$$

Tableau 1.5 – Exemple de distribution conditionnelle de la variable Y pour $X = x_2$: distribution des étudiants de la filière B selon les classes des notes.

Classe de notes	[0 ; 6[	[6 ; 10[	[10 ; 14[	[14 ; 20[
Fréquence en % ($f_{j/2}$)	48,00	36,00	12,00	4,00

$$\bar{y}_2 = \sum_{j=1}^4 f_{j/2} * y_j = 6,44 \text{ et } \sigma_i^2 = \sum_{j=1}^4 f_{j/2} (y_j - \bar{y}_2)^2 = 14,73$$

$$\bar{y} = \sum_{i=1}^4 f_{i\bullet} \bar{y}_i = 6,96$$

Symétriquement, on a l distributions conditionnelles de X et on définit les fréquences conditionnelles $f_{i/j}$ indice i si j :

$$f_{i/j} = \frac{n_{ij}}{n_{\bullet j}} \text{ avec : } \sum_{i=1}^k f_{i/j} = 1$$

$X/Y = y_j$	x_1	...	x_i	...	x_k	Total
Fréquence	$f_{1/j}$	...	$f_{i/j}$	...	$f_{k/j}$	1

Lorsque la variable X est quantitative, on peut calculer pour chaque valeur y_j sa moyenne conditionnelle $\bar{x}_j$ et son écart-type conditionnel σ_j^2 :

$$\bar{x}_j = \sum_{i=1}^k f_{i/j} x_i \text{ et } \sigma_j^2 = \sum_{i=1}^k f_{i/j} (x_i - \bar{x}_j)^2$$

Et on a la relation suivante entre la moyenne $\bar{x}$ et les l moyennes conditionnelles $\bar{x}_j$

$$\bar{x} = \sum_{j=1}^l f_{\bullet j} \bar{x}_j$$

Lorsqu'on dispose d'observations portant simultanément sur deux variables, il est fréquent de les présenter dans un tableau donnant l'ensemble des distributions conditionnelles de Y , et on a alors un tableau dont toutes les sommes en ligne sont égales à 100 % ; ce tableau est appelé *tableau des profils en ligne*. (Cf. tableau 1.5).

Tableau 1.5 – Tableau des profils en ligne

Modalités de Y Modalités de X	y_1	...	y_j	...	y_l	Total
	y_1	...	y_j	...	y_l	Total
x_1	$f_{1/1}$	...	$f_{j/1}$	...	$f_{l/1}$	100
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	$f_{1/i}$	...	$f_{j/i}$	...	$f_{l/i}$	100
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_k	$f_{1/k}$	...	$f_{j/k}$	...	$f_{l/k}$	100
Distribution marginale de Y	$f_{\bullet 1}$	...	$f_{\bullet j}$	...	$f_{\bullet l}$	100

Exemple

Tableau 1.6 – Tableau des profils en ligne correspondant au tableau de contingence 1.2

Classe de notes Y	[0 ; 6[	[6 ; 10[	[10 ; 14[	[14 ; 20[	Total
Filière d'origine X	3	8	12	17	
Filière A	70,3	16,2	10,8	2,7	100,0
Filière B	48,0	36,0	12,0	4,0	100,0
Filière C	6,3	25,0	31,3	37,5	100,0
Filière D	45,5	36,4	13,6	4,5	100,0
Distribution marginale de Y	49,0	27,0	15,0	9,0	100,0

Bien évidemment, on définit d'une façon symétrique le tableau des profils en colonne qui est le tableau des distributions conditionnelles de X avec des sommes en colonne égales à 100 (cf. tableau 1.7).

Tableau 1.7 – Tableau des profils en colonne

Modalités de Y	y_1	...	y_j	...	y_l	Distribution marginale de X
Modalités de X						
x_1	$f_{1/1}$	...	$f_{1/j}$	...	$f_{1/l}$	$f_{1\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	$f_{i/1}$	...	$f_{i/j}$	...	$f_{i/l}$	$f_{i\bullet}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_k	$f_{k/1}$	...	$f_{k/j}$	...	$f_{k/l}$	$f_{k\bullet}$
Total	100	...	100	...	100	100

D. Dépendance et indépendance statistique

Si tous les profils en colonne du tableau 1.4 sont identiques, cela signifie que la distribution de la variable X ne dépend pas de la variable Y , on dit alors que les variables X et Y sont statistiquement indépendantes dans l'ensemble des n individus considérés, et dans ce cas toutes les distributions conditionnelles de X sont identiques à la distribution marginale de X . en d'autres termes, $f_{i/j}$ ne dépend pas de j . c.-à-d. Pour tout i , on doit avoir parmi les $n_{i\bullet}$ individus possédant la modalité x_i , $f_{\bullet j} \cdot n_{i\bullet}$ individus possédant la modalité y_j .

On peut écrire en termes d'effectifs ou de fréquences ce que signifie l'indépendance statistique entre X et Y ; pour tout couple (i, j) : Le nombre d'individus possédant à la fois la modalité x_i de X et la modalité y_j de Y devrait être égale à :

$$n_{ij}^* = \frac{n_{i\bullet} \cdot n_{\bullet j}}{n} \text{ et } f_{ij}^* = f_{i\bullet} \cdot f_{\bullet j}$$

les n_{ij}^* et f_{ij}^* sont appelés respectivement les effectifs et fréquences théoriques.

Par raison de symétrie, l'indépendance statistique entre X et Y implique aussi des profils en ligne identiques à la distribution marginale de Y : $f_{j/i} = f_{\bullet j}$ pour tout couple (i, j) .

Lorsque deux variables dépendent statistiquement l'une de l'autre, on cherche à évaluer l'intensité de leur liaison et dans le cas de deux variables quantitatives, on examine si on peut les considérer liées par une relation linéaire.

Chapitre 2 : Deux variables quantitatives

Si les observations de deux variables statistiques X et Y sont connues individuellement, on commence par les visualiser en les représentant sous la forme d'un nuage de points (cf. figure 1.1) : dans un repère cartésien, chaque observation (x_i, y_i) est figurée par le point M_i de coordonnées (x_i, y_i) , et la forme du nuage donne une information sur le type d'une éventuelle liaison.




Figure 1.1- Nuages de points

Supposons que l'examen du nuage de points conduise à rechercher une droite d'ajustement. Le calcul des coefficients de cette droite va être exposé dans le cas où les observations sont connues individuellement. La généralisation des résultats au cas d'une distribution résumée dans un tableau de contingence se fait sans difficulté.

A. Caractéristiques d'un couple de deux variables quantitatives

1) Moyenne d'une somme de deux variables statistiques

On montre sans difficulté le résultat suivant : $\overline{ax + by} = a\bar{x} + b\bar{y}$

$$\Rightarrow \forall a, b, c \in \mathbb{R} \quad \overline{ax + by + c} = a\bar{x} + b\bar{y} + c$$

2) Covariance entre deux variables statistiques

Cas de données individuelles :	Cas de données groupées
$\text{COV}(X, Y) = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{x}) (y_i - \bar{y})$ $= \frac{1}{N} \sum_{i=1}^n x_i y_i - \bar{x} \cdot \bar{y}$	$\text{COV}(X, Y) = \sum_{i=1}^k \sum_{j=1}^l f_{ij} (x_i - \bar{x}) (y_j - \bar{y})$ $= \sum_{i=1}^k \sum_{j=1}^l f_{ij} x_i y_j - \bar{x} \cdot \bar{y}$

Propriétés de la covariance

1. $\text{cov}(X, Y) = \text{cov}(Y, X)$
2. $\text{cov}(X, X) = \text{var}(X)$
3. $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2 \text{cov}(X, Y)$
4. $\forall a, b, c, x_0, y_0 \in \mathbb{R} : \text{cov}(aX + x_0, bY + y_0) = ab \text{cov}(X, Y)$
 $\Rightarrow \text{var}(aX + bY + C) = a^2 \text{var}(X) + b^2 \text{var}(Y) + 2ab \text{cov}(X, Y)$
5. $|\text{cov}(X, Y)| \leq \sqrt{\text{var}(X) \text{var}(Y)}$.

3) Coefficient de corrélation linéaire de Pearson

On appelle coefficient de corrélation linéaire entre deux variables statistiques X et Y , le rapport de leur covariance par le produit de leurs écarts-types :

$$r(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_x \cdot \sigma_y}.$$

Propriétés du coefficient de corrélation linéaire

1. On a pour tout $a, b, c, x_0, y_0 \in \mathbb{R}$:

$$r(aX + x_0, bY + y_0) = \frac{\text{cov}(aX + x_0, bY + y_0)}{\sigma_{aX+x_0} \cdot \sigma_{bY+y_0}} = \frac{ab \text{cov}(X, Y)}{|ab| \sigma_X \cdot \sigma_Y}$$

$$= \begin{cases} +r(X, Y) & \text{si } a \text{ et } b \text{ de même signe} \\ -r(X, Y) & \text{si } a \text{ et } b \text{ de signe opposé} \end{cases}$$

1. Ce coefficient, invariant par changement d'origine et d'échelle, est un nombre sans dimension, qui varie entre -1 et +1
2. S'il est égal à ± 1 , les N points (x_i, y_i) sont alignés.


B. Ajustement linéaire d'un nuage de point

Soient les n points du nuage représentant, dans un repère cartésien, la série des n valeurs (x_i, y_i) des variables X et Y . Ajuster une droite D à ce nuage de points consiste à remplacer chaque point $M_i(x_i, y_i)$ par un point de même abscisse et d'ordonnée $\hat{y}_i$, les points $(x_i, \hat{y}_i)$ étant alignés sur la droite D .

1) Ajustement par la méthode graphique

- **Méthode :**

La méthode graphique consiste à tracer, à l'œil, à l'aide d'une règle transparente, une droite $y = ax + b$ s'ajustant le mieux possible sur le nuage de points.



Les points noirs représentent les données.

Les points rouges A et B sont les points choisis pour tracer la droite.

- **Équation de la droite d'ajustement**

Une fois la droite tracée, on choisit sur le graphique deux points A et B quelconques de la droite pour en déterminer l'équation. Ces points ne doivent pas obligatoirement faire partie du nuage de points.

L'équation de la droite passant par les points $A(x_A, y_A)$ et $B(x_B, y_B)$ est donnée par :

$$y - y_B = \frac{y_B - y_A}{x_B - x_A} (x - x_B).$$

2) Ajustement par la méthode de Mayer

- **Méthode :**

On découpe le nuage de points en deux sous-ensembles de même effectif. Pour chacun des deux sous-ensembles, on calcule la moyenne des x_i et la moyenne des y_i . On obtient ainsi deux points $G_1(\bar{x}_1, \bar{y}_1)$ et $G_2(\bar{x}_2, \bar{y}_2)$, appelés **points moyens**. Il reste à tracer la droite passant par ces deux points.

- **Équation de la droite d'ajustement**

L'équation de cette droite s'obtient de la même façon que pour un ajustement graphique. Il s'agit de la droite dite **Droite de Mayer** passant par les deux points G_1 et G_2 . L'équation de la droite de Mayer est donnée par : $y - \bar{y}_2 = \frac{\bar{y}_2 - \bar{y}_1}{\bar{x}_2 - \bar{x}_1} (x - \bar{x}_2)$

3) Ajustement par la méthode des moindres carrés

Les points (x_i, y_i) forment un nuage dont on cherche une approximation. Nous allons chercher la **meilleure droite au sens des moindres carrés**, c'est-à-dire telle que : $\sum_{i=1}^n |M_i H_i|^2$ soit minimum (cf. figure 1.2) :




Figure 1.2 – Interprétation géométrique de la droite des moindres carrés

Les distances sont comptées parallèlement à l'un des axes des coordonnées ; nous avons choisi ici l'axe des ordonnées (cf. figure 1.2).

Il s'agit de déterminer la droite $\mathbb{D}$ d'équation $\{y = ax + b\}$ telle que :

$$F(a, b) = \sum_{i=1}^n (y_i - (ax_i + b))^2 \text{ soit minimum.}$$

Nos inconnues sont a et b .

Commençons par chercher le minimum de $F(a, b)$ relativement à b lorsque a est fixé. On peut écrire $F(a, b)$ comme un trinôme du second degré en b :

$$\begin{aligned} F(a, b) &= \sum_{i=1}^N ((y_i - ax_i) - b)^2 = \sum_{i=1}^N ((y_i - ax_i)^2 - 2b(y_i - ax_i) + b^2) \\ &= \sum_{i=1}^n (y_i - ax_i)^2 - 2b \sum_{i=1}^n (y_i - ax_i) + nb^2 \end{aligned}$$

Quand a est fixé, le dernier membre constitue une fonction de b qui atteint son minimum pour $b = \hat{b}$ tel que $\frac{\partial}{\partial b} F(a, \hat{b}) = 0$, soit :

$$\begin{aligned} \frac{\partial}{\partial b} F(a, \hat{b}) &= -2 \left(\sum_{i=1}^n (y_i - ax_i) - n\hat{b} \right) = 0 \\ \Rightarrow \hat{b} &= \frac{1}{N} \sum_{i=1}^n (y_i - ax_i) = \bar{y} - a\bar{x} \end{aligned}$$

Notre problème est maintenant de trouver le minimum de $F(a, \hat{b})$ relativement à a :

$$\begin{aligned} F(a, \hat{b}) &= \sum_{i=1}^n ((y_i - \bar{y}) - a(x_i - \bar{x}))^2 \\ &= \sum_{i=1}^N (y_i - \bar{y})^2 - 2a \sum_{i=1}^N (y_i - \bar{y})(x_i - \bar{x}) + a^2 \sum_{i=1}^N (x_i - \bar{x})^2 \end{aligned}$$

ce qui peut encore s'écrire :

$$F(a, \hat{b}) = N(a^2 \text{var}(X) - 2a \text{cov}(X, Y) + \text{var}(Y))$$

Le coefficient de a^2 étant positif ou nul, ce trinôme du second degré en a atteint son minimum relativement à a pour $a = \hat{a}$ avec :

$$\hat{a} = \frac{\text{cov}(X, Y)}{\text{var}(X)}$$

Ainsi le couple $(\hat{a}, \hat{b})$ avec $\hat{b} = \bar{y} - \hat{a}\bar{x}$ réalise le minimum de la fonction F .

Par conséquent, la droite des moindres carrés a pour équation : $y = \hat{a}x + \hat{b}$.
Soit :

$$y - \bar{y} = \frac{\text{cov}(X, Y)}{\text{var}(X)} (x - \bar{x})$$

On posera pour tout i variant de 1 à n : $\hat{y}_i = \hat{a}x_i + \hat{b}$, est la valeur estimée de Y par la droite des moindres carrés lorsque $X = x_i$.

4) Interprétation du coefficient de corrélation linéaire

1) Droite des moindres carrés $\mathbb{D}$

Il est d'autant plus légitime de remplacer le nuage de points par la droite des moindres carrés que la dispersion du nuage par rapport à cette droite : $\sum_{i=1}^N (y_i - \hat{y}_i)^2$ sera plus faible.

Comme $\hat{y}_i = \hat{a}x_i + \hat{b}$, en remplaçant $\hat{a}$ et $\hat{b}$ par leur valeur, on obtient :

$$\begin{aligned} \sum_{i=1}^N (y_i - \hat{y}_i)^2 &= n \left(\frac{(\text{cov}(X, Y))^2}{\text{var}(X)} - 2 \frac{(\text{cov}(X, Y))^2}{\text{var}(X)} + \text{var}(Y) \right) \\ &= n \left(\text{var}(Y) - \frac{(\text{cov}(X, Y))^2}{\text{var}(X)} \right) \end{aligned}$$

et comme

$$r^2 = \frac{(\text{cov}(X, Y))^2}{\text{var}(X) \cdot \text{var}(Y)}$$

on a :

$$\begin{aligned} \sum_{i=1}^N (y_i - \hat{y}_i)^2 &= n \cdot \text{var}(Y)(1 - r^2) \\ \Leftrightarrow \sum_{i=1}^N (y_i - \hat{y}_i)^2 &= \sum_{i=1}^n (y_i - \bar{y})^2 \cdot (1 - r^2) \end{aligned}$$

ce qui implique :

$$1 - r^2 \geq 0 \Rightarrow |r| \leq \pm 1 \text{ et } |\text{cov}(X, Y)| \leq \sqrt{\text{var}(X) \cdot \text{var}(Y)}$$

La quantité $\sum_{i=1}^N (y_i - \hat{y}_i)^2$ appelée *Somme des Carrés Résiduelle (SCR)*, est d'autant plus faible que r^2 est proche de 1.

Elle est nulle pour $r = \pm 1$ et dans ce cas, on a une liaison linéaire entre X et Y , car si $\{\hat{y}_i = y_i \text{ pour tout } i\}$, alors les n points (x_i, y_i) sont alignés.

La quantité $\sum_{i=1}^n (y - \bar{y})^2$ étant appelée *Somme des Carrés Totale (SCT)* de Y , il s'ensuit :

$$1 - r^2 = \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} = \frac{SCR}{SCT}$$

⇒ La quantité $\{1 - r^2\}$ est égale à la proportion de variation de Y non expliquée par la droite des moindres carrés $\mathbb{D}$ (cf. figures 1.3 et 1.4).




Figure 1.3 – $\sum_{i=1}^N (y_i - \hat{y}_i)^2 = SCR$




Figure 1.4 – $\sum_{i=1}^n (y_i - \bar{y})^2 = SCT$

Notons que la somme des écarts à la droite $\mathbb{D}$ est nulle :

$$y = \hat{a}x + \hat{b} \Rightarrow \sum_{i=1}^n (y_i - \hat{a}x_i - \hat{b}) = 0 \Rightarrow \sum_{i=1}^n (y_i - \hat{y}_i) = 0$$

Ce qui implique aussi que les moyennes des $\hat{y}_i$ et des y_i sont égales :

$\bar{\hat{y}} = \bar{y}$ et ceci est dû au fait que la droite des moindres carrés passe par le point moyen $(\bar{x}, \bar{y})$ du nuage des n points.

La décomposition de la variation totale de Y permet une autre interprétation de r^2 :

$$\begin{aligned} \sum_{i=1}^n (y_i - \bar{y})^2 &= \sum_{i=1}^n (y_i - \hat{y}_i + \hat{y}_i - \bar{y})^2 \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) \end{aligned}$$

Le 3^e terme du dernier membre est nul.

La quantité $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ étant appelée Somme des Carrés Expliquée (SCE), on obtient l'équation de la décomposition de la variation totale de Y :

$$\sum_{i=1}^N (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \Leftrightarrow SCT = SCE + SCR$$

et une autre interprétation de r^2 , complémentaire à celle de $\{1 - r^2\}$:

$$r^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{SCE}{SCT}$$

⇒ Le carré r^2 du coefficient de corrélation linéaire est égal à la proportion de la variation de Y expliquée par la droite des moindres carrés $\mathbb{D}$.

Conclusion sur l'interprétation de la valeur du coefficient de corrélation Linéaire :

$r = \pm 1 \Leftrightarrow$ les n points (x_i, y_i) sont alignés
 $r = 0 \Leftrightarrow$ pas de liaison linéaire, mais possibilité d'une liaison d'un autre type
 X et Y indépendantes $\Rightarrow r(X, Y) = 0$
 $\nRightarrow$

2) Droite des moindres carrés $\mathbb{D}'$

Dans toute l'étude précédente, on a procédé comme si la variable X pouvait être mesurée, et qu'on cherchait à prévoir la variable Y .

Inversement, la droite $\mathbb{D}'$ des moindres carrés pour laquelle les distances sont comptées parallèlement à l'axe des abscisses (cf. figure 1.5) a pour équation :

$$x - \bar{x} = \frac{\text{cov}(X, Y)}{\text{var}(Y)} \cdot (y - \bar{y}) \Rightarrow y - \bar{y} = \frac{\text{var}(Y)}{\text{cov}(X, Y)} \cdot (x - \bar{x})$$

Mais, dans certains cas, comme celui où la variable X désigne le temps, seule la droite $\mathbb{D}$ a un sens.

Le coefficient r étant symétrique par rapport à X et à Y , la *Somme des Carrés Résiduelle* associée à la droite $\mathbb{D}'$ est égale à :

$$\sum_{i=1}^n |M_i G_i|^2 = \sum_{i=1}^n (x_i - \hat{x}_i)^2 = n \text{var}(X) \cdot (1 - r^2)$$




Figure 1.5 – Interprétation géométrique de la droite des moindres carrés $\mathbb{D}'$

4) Comparaison des deux droites des moindres carrés

Les deux droites $\mathbb{D}$ et $\mathbb{D}'$ sont généralement distinctes. Elles se coupent au point moyen du nuage, et leurs coefficients directeurs sont de même signe et du signe de r :

$$\frac{\text{cov}(X,Y)}{\text{var}(X)} = r \sqrt{\frac{\text{var}(Y)}{\text{var}(X)}} \quad \text{et} \quad \frac{\text{var}(Y)}{\text{cov}(X,Y)} = \frac{1}{r} \sqrt{\frac{\text{var}(Y)}{\text{var}(X)}}$$

De plus, la valeur absolue du coefficient de corrélation r étant comprise entre 0 et 1, la valeur absolue de la pente de la droite $\mathbb{D}$ est toujours inférieure ou égale à celle de la droite $\mathbb{D}'$ (cf. figure 1.6).

Ces deux droites seront confondues si et seulement si les variables X et Y sont liées par une relation linéaire :

$$r = \frac{1}{r} \Rightarrow r = \pm 1$$




Figure 1.6 – Positions respectives des droites des moindres carrés selon les valeurs de r

Chapitre 3 : Une variable qualitative et une variable quantitative

Soient n observations portant simultanément sur une variable qualitative X à k modalités $\{x_1, \dots, x_i, \dots, x_k\}$ et sur une variable quantitative Y à l modalités $\{y_1, \dots, y_j, \dots, y_l\}$

A. Variances inter-groupes et intra-groupes

On suppose à présent que l'on dispose de n individus (observations) réparties en k sous-groupes. L'effectif de chaque sous-groupe est noté n_i (avec $i \in \llbracket 1, k \rrbracket$), de telle sorte que

$$n_1 + \dots + n_k = n.$$

Une même variable Y a été mesurée sur chaque modalité, et on note y_{ij} la valeur obtenue du $i^{\text{ème}}$ groupe sur la $j^{\text{ème}}$ modalité de Y .

On note $\bar{y}$ la moyenne totale de la série étudiée, sans distinction de groupes :

$$\bar{y} = \frac{1}{n} \left(\sum_{i=1}^k \sum_{j=1}^l n_{ij} y_{ij} \right)$$

On note $\bar{y}_i$ la moyenne des valeurs appartenant au i -ème groupe :

$$\bar{y}_i = \frac{1}{n_i} \sum_{j=1}^l n_{ij} y_j$$

et σ_i^2 la variance des valeurs appartenant au $i^{\text{ème}}$ groupe :

$$\sigma_i^2 = \frac{1}{n_i} \sum_{j=1}^l n_{ij} (y_j - \bar{y}_i)^2$$

1) Variance intra-groupes

On appelle alors, pour l'ensemble des individus, variance intra-groupes, notée V_{intra} la moyenne pondérée des k variances σ_i^2 mesurées à l'intérieur de chaque groupe :

$$V_{intra} = \frac{1}{n} \sum_{i=1}^k n_i \sigma_i^2$$

La variance intra-groupes donne donc une idée de la variabilité à l'intérieur de chaque groupe : si cette variance est plutôt faible alors chacun des groupes est constitué d'individus relativement homogènes ; si

elle est plutôt élevée alors les groupes rassemblent en leur sein des individus assez peu semblables.

2) Variance inter-groupes

On appelle, pour l'ensemble des observations, variance inter-groupes, notée V_{inter} la variance (pondérée) de la série statistique $(\bar{y}_i)_{i=1,\dots,k}$:

$$V_{inter} = \frac{1}{n} \sum_{i=1}^k n_i (\bar{y}_i - \bar{y})^2$$

La variance inter-groupes donne quant à elle une idée de la variabilité entre les différents ensembles (groupes) : la différenciation entre les groupes est d'autant plus prononcée que cette variance est élevée




Figure 3.1 Illustration graphique des variances intra et inter-groupes

3) Décomposition de la variance

On peut démontrer que la variance totale de la série (*i.e.* calculée sur l'ensemble de tous les individus sans distinction de groupes), est égale à la somme de la variance inter-groupes et de la variance intra-groupes :

$$\sigma^2 = V_{inter} + V_{intra}$$

B. Mesure de la liaison par le rapport de corrélation

Soient X une variable qualitative à k modalités et Y une variable quantitative. Ces deux variables sont mesurées sur n individus, et on suppose que chacune des k modalités de X est présentée sur au moins deux individus. Les individus sont alors naturellement répartis en k groupes correspondant aux k modalités de X .

1) Définition du rapport de corrélation

Le **rapport de corrélation** de Y en X , notée $\rho_{Y/X}$ est le rapport de la variance inter-groupes sur la variance totale :

$$\rho_{Y/X} = \frac{V_{inter}}{V_{inter} + V_{intra}} = \frac{V_{inter}}{\sigma^2}$$

2) Interprétation du rapport de corrélation

- Le rapport de corrélation est toujours compris entre 0 et 1.
- Il est égal à 0 si la variance inter-groupes est nulle, c'est-à-dire si les moyennes conditionnelles $\bar{y}_i$ sont toutes égales à $\bar{y}$, mais cette condition n'est pas suffisante à l'indépendance des variables X et Y .
- Il est égal à 1 si la variance intra-groupes est nulle, donc si à chaque modalité x_i de X , correspond une seule valeur de Y égale à $\bar{y}_i$

Dans ce cas, la variable Y est liée fonctionnellement à la variable X .

- Les deux cas précédents correspondent à deux situations théoriques qu'on ne rencontre pas dans la pratique.
- En général, $0 < \rho_{Y/X} < 1$ et plus $\rho_{Y/X}$ est proche de 1, plus la liaison entre X et Y est forte.

Chapitre 4 : Deux variables qualitatives

Les données relatives aux observations portant simultanément sur deux variables qualitatives X et Y sont généralement présentées dans un tableau de contingence (cf. tableau 1.1), ou dans un tableau de profils en ligne ou en colonne (cf. tableaux 1.3 et 1.4).

À condition de disposer des *effectifs marginaux*, on peut retrouver le tableau de contingence à partir d'un tableau de profils en ligne ou en colonne.

La question qui se pose est celle de l'existence d'une liaison entre les deux caractères X et Y .

A. Coefficient du khi- deux

La comparaison des effectifs théoriques (ou « attendus ») sous l'hypothèse d'indépendance ($n_{ij}^* = \frac{n_{i.} \cdot n_{.j}}{n}$) et des effectifs observés n_{ij} donne une idée de la dépendance entre X et Y . Mais pour être plus précis, il convient de calculer l'écart entre ces effectifs théoriques et observés.

Pour des raisons théoriques, la mesure usuellement adoptée est celle du χ^2 (Khi-deux) qui peut être considérée comme *un coefficient d'association* entre deux variables :

$$\chi^2 = \sum_{i,j} \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*} = n * \sum_{i,j} \frac{(f_{ij} - f_{ij}^*)^2}{f_{ij}^*} \text{ avec : } f_{ij}^* = f_{i.} \cdot f_{.j} = \frac{n_{ij}^*}{n}$$

Remarques :

- On a $\chi^2 \geq 0$. Plus il est grand plus le lien est fort.
- Le χ^2 est nul lorsque les effectifs théoriques et observés coïncident, et plus les effectifs théoriques et observés diffèrent, plus sa valeur est élevée.

B. Le V de Cramer

Le χ^2 varie de 0 à $+\infty$. Il nous faudrait une mesure normalisée dont on connaît la valeur maximale lorsque la liaison est parfaite c.-à-d. lorsque la connaissance de Y permet de déterminer avec certitude la valeur de X et/ou inversement.

Le V de Cramer défini par $\varphi = \sqrt{\frac{\chi^2}{n \cdot \min(k-1, l-1)}}$.

Avec : $k - 1$ = le nombre de lignes -1
 $l - 1$ = le nombre de colonnes -1

Remarques :

- On a $0 \leq V \leq 1$
- Le V de Cramer s'interprète :

$0 < V \leq 0.2$	$0.2 < V \leq 0.5$	$0.5 < V \leq 0.9$	$0.9 < V \leq 1$
Lien faible	Lien modéré	Lien fort	Lien très fort