

LA RELATION ENTRE 2 VARIABLE :

1° ÉTUDE DE LA RELATION ENTRE DEUX VARIABLES :

La corrélation entre deux variables est le lien (dépendance statistique) qui unit ces deux variables. C'est ce que nous recherchons.

DISTRIBUTION À DEUX CARACTÈRES :

Une distribution à deux caractères : correspond à l'ensemble des couples de données recueillies au cours d'une étude statistique portant sur deux caractères issus d'une même situation.

Dans une étude statistique, on donne le nom de variable statistique à tout caractère dont les données peuvent être différentes.

CORRÉLATION : Étudier la corrélation entre deux variables statistiques, c'est décrire le lien entre deux caractères quantitatifs d'une distribution.

Il est possible de qualifier le type, le sens et l'intensité d'une corrélation entre deux variables :

- Le type de corrélation correspond au modèle mathématique qui décrit le mieux le lien entre les variables.
- Une corrélation est dite positive ou négative selon le sens de variation des variables.
- Une corrélation est dite nulle, faible, moyenne, forte ou parfaite selon l'intensité du lien entre les variables.

NUAGE DE POINTS : Un nuage de points permet de représenter une distribution à deux variables et de qualifier le type, le sens et l'intensité de la corrélation qui peut exister entre les deux variables.

Dans un nuage de points :

- l'une des variables est associée à l'axe des abscisses et l'autre variable, à l'axe des ordonnées ;
- chacun des couples de la distribution est représenté par un point ;
- la corrélation est dite linéaire lorsque les points tendent à former une droite .

Cette corrélation est dite nulle si les points sont distribués au hasard, et de plus en

plus forte au fur et à mesure que les points se rapprochent d'une droite.

(le coefficient de corrélation) : C'est une technique qui permet d'étudier la relation qui pourrait exister entre deux variables quantitatives X et Y:

- **Corrélation positive**, c'est-à-dire à toute augmentation au niveau de X correspond une augmentation au niveau de Y. Les deux variables varient dans le même sens et avec une intensité similaire. Exemple: la taille et le poids

- **Corrélation négative**, c'est-à-dire à toute augmentation au niveau de X correspond une diminution au niveau de Y.

Les deux variables varient dans deux sens opposés et avec une intensité similaire

Le coefficient de corrélation de Bravais-Pearson :

Le coefficient de corrélation de Bravais-Pearson est un indice statistique qui exprime l'intensité et le sens (positif ou négatif) de la relation linéaire entre deux variables quantitatives.

C'est une mesure de la liaison linéaire, c'est à dire de la capacité de prédire une variable x par une autre y à l'aide d'un modèle linéaire.

Il permet de mesurer l'intensité de la liaison entre deux caractères quantitatifs.

C'est donc un paramètre important dans l'analyse des régressions linéaires (simples ou multiples).

En revanche, ce coefficient est nul ($r = 0$) lorsqu'il n'y a pas de relation linéaire entre les variables (ce qui n'exclut pas l'existence d'une relation autre que linéaire).

Par ailleurs, Le coefficient est de signe positif si la relation est positive (directe, croissante) et de signe négatif si la relation est négative (inverse, décroissante).

Ce coefficient varie entre -1 et +1 ; l'intensité de la relation linéaire sera donc d'autant plus forte que la valeur du coefficient est proche de +1 ou de - 1, et d'autant plus faible qu'elle est proche de 0.




1° : Le coefficient de corrélation Pearson entre deux variables X et Y se calcule à partir de la Covariance et des écart-types en appliquant la formule suivante :

$$r = \frac{COV(x, y)}{\sigma_x \sigma_y}$$


avec : $COV(x ; y) = 1 / N [\sum xy] - \bar{x} \bar{y}$

$$V(X) = 1 / N [\sum x^2] - \bar{x}^2 \quad V(Y) = 1 / N [\sum y^2] - \bar{y}^2$$


La forme de la relation entre X et Y :




Absence de corrélation
linéaire



parfaite corrélation



corrélation non-



Corrélation partielle

corrélation non-linéaire

parfaite corrélation

2° : Le coefficient de corrélation de rang de Spearman.

Le coefficient de corrélation de rang (appelé coefficient de Spearman) examine s'il existe une relation entre le rang des observations pour deux caractères X et Y, ce qui permet de détecter l'existence de relations monotones (croissante ou décroissante), quelle que soit leur forme précise (linéaire, exponentiel, puissance, ...). Ce coefficient est donc très utile lorsque l'analyse du nuage de point révèle une forme curviligne dans une relation qui semble mal s'ajuster à une droite. On notera également qu'il est préférable au coefficient de Pearson lorsque les distributions X et Y sont dissymétriques et/ou comportent des valeurs exceptionnelles.

Le coefficient de Spearman est fondé sur l'étude de la différence des rangs entre les attributs des individus pour les deux caractères X et Y :

$$r_s(X, Y) = 1 - \frac{6 \cdot \sum_{i=1}^N [r(X_i) - r(Y_i)]^2}{N^3 - N}$$

avec

$r(X_i)$: rang de X_i dans la distribution $X_1 \dots X_N$

$r(Y_i)$: rang de Y_i dans la distribution $Y_1 \dots Y_N$

Ce coefficient varie entre -1 et +1. Son interprétation est la même que celui de Pearson, mais il permet de mettre en évidence des relations non-linéaires lorsqu'elles sont positives ou négatives.