

Techniques de sondage
2ème Année Techniques Commerciales et Marketing

Chapitre 3 : La distribution d'échantillonnage

Nous allons voir dans ce chapitre, comme dans le chapitre suivant comment les résultats obtenus sur un échantillon peuvent être utilisés pour décrire la population. On verra en particulier que les statistiques sont utilisées pour estimer les paramètres.

Afin de ne pas confondre les statistiques et les paramètres, on utilise des notations différentes, comme le présente le tableau récapitulatif suivant.

	Population	Échantillon
Définition	C'est l'ensemble des unités considérées par le statisticien.	C'est un sous-ensemble de la population choisie pour étude.
Caracteristiques	Ce sont les paramètres	Ce sont les statistiques
Notations	N = taille de la population (si elle est finie)	n = taille de l'échantillon
Si on étudie un caractère quantitatif	moyenne de la population $m = \frac{1}{N} \sum_{i=1}^N x_i$ écart-type de la population $\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - m)^2}$	moyenne de l'échantillon $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ écart-type de l'échantillon $\sigma_{\bar{x}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$
Si on étudie un qualitatif	proportion dans la population p	proportion dans l'échantillon f .

1 La distribution d'échantillonnage de la moyenne :

Introduction :

Position du problème :

Si nous prélevons un échantillon de taille n dans une population donnée, la moyenne de l'échantillon nous donnera une idée approximative de la moyenne de la population. Seulement si nous prélevons un autre échantillon de même taille, nous obtiendrons une autre moyenne d'échantillon. Sur l'ensemble des échantillons possibles, on constatera que certains ont une moyenne proche de la moyenne de la population et que d'autres ont une moyenne qui s'en écarte davantage.

Comment traiter le problème ? Un échantillon de taille n (appelé aussi un n -échantillon), obtenu par échantillonnage aléatoire, va être considéré comme le résultat d'une expérience aléatoire. A chaque échantillon de taille n on peut associer la valeur moyenne des éléments de l'échantillon. On a donc défini une variable aléatoire qui à chaque n -échantillon associe sa moyenne échantillonnale. On la note $\bar{X}$. Cette variable aléatoire possède bien entendu :

- Une distribution de probabilité.
- Une valeur moyenne (la moyenne des moyennes d'échantillons, vous suivez toujours?).
- Un écart-type.

Le but de ce paragraphe est de déterminer ces trois éléments.

Avant de continuer, essayons de comprendre sur un exemple ce qui se passe.

Exemple : Supposon qu'on a une population de $N = 5$ étudiants. X_i le nombre d'heures passées devant le PC.



Etudiant	A	B	C	D	E
X_i	7h	16h	20h	12h	22h

La moyenne de la population est $m = \frac{\sum_{i=1}^N X_i}{N} = \frac{7 + 16 + 20 + 12 + 22}{5} = 15.4$.

Si on divise la population en échantillons de taille $n = 3$ on trouve :

$$C_n^p = \frac{n!}{p!(n-p)!} = \frac{5 \times 4 \times 3 \times 2 \times 1}{(3 \times 2 \times 1)(2 \times 1)} = 10.$$

Toutes les possibilités sont regroupées dans le tableau ci-dessous.

Numéro de l'échantillon	Échantillon	x_1	x_2	x_3	Moyennes de l'échantillon
1	A, B, C	7	16	20	14.33
2	A, B, D	7	16	12	11.67
3	A, B, E	7	16	22	15
4	A, C, D	7	20	12	13
5	A, C, E	7	20	22	16.33
6	A, D, E	7	12	22	13.67
7	B, C, D	16	20	12	16
8	B, C, E	16	20	22	19.33
9	B, D, E	16	12	22	16.67
10	C, D, E	20	12	22	18
Total					154

On définit la moyennes des moyennes $\bar{X}$ par :

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n} = \frac{\sum_{i=1}^{10} X_i}{10} = \frac{154}{10} = 15.4.$$

On applique les propriétés de l'espérance et de la variance :

1.

$$\begin{aligned}
 E(\bar{X}) &= E\left(\frac{\sum_{i=1}^n X_i}{n}\right) \\
 &= \frac{1}{n} \sum_{i=1}^n E(X_i) \\
 &= \frac{1}{n} \times n \times m \\
 &= m,
 \end{aligned}$$

car les variables suivent toutes la même loi l'espérance m .



Tirage avec remise (TAR) :

$$\begin{aligned} V(\bar{X}) &= V\left(\frac{\sum_{i=1}^n X_i}{n}\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n V(X_i) \\ &= \frac{1}{n^2} \times n \times \sigma^2 \\ &= \frac{\sigma^2}{n}, \end{aligned}$$

alors

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}},$$

car les variables suivent toutes la même loi de variance et sont indépendantes.

– Tirage sans remise (TSR) :

$$\begin{aligned} V(\bar{X}) &= V\left(\frac{\sum_{i=1}^n X_i}{n}\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n V(X_i) \\ &= \frac{1}{n^2} \times n \times \sigma^2 \times \frac{N-n}{N-1} \\ &= \frac{\sigma^2}{n} \times \frac{N-n}{N-1}, \end{aligned}$$

alors

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} \times \sqrt{\frac{N-n}{N-1}}.$$

2 La distribution d'échantillonnage de la proportion :

Il arrive fréquemment que nous ayons à estimer dans une population une proportion p d'individus possédant un caractère qualitatif donné.

Bien sûr, cette proportion p sera estimée à l'aide des résultats obtenus sur un n -échantillon. La proportion f obtenue dans un n -échantillon est la valeur observée d'une variable aléatoire F , fréquence d'apparition de ce caractère dans un échantillon de taille n , appelée proportion d'échantillon. On se pose la question. La moyenne des fréquences d'observation du caractère sur l'ensemble de tous les échantillons de taille n est-elle égale à la proportion p de la population ?.



Exemple : Supposon que on a une poulation de 7 personne (3 Garçons et 4 Filles) . X_i le nombre de filles.

$$\text{Alors } p = \frac{X_i}{N} = \frac{4}{7}.$$

Si on divise la population en échantillons de taille $n = 6$ on trouve :

$$C_n^p = \frac{n!}{p!(n-p)!} = \frac{7!}{6!(7-6)!} = \frac{7 \times 6 \times 5 \times 4 \times 3 \times 2 \times 1}{(6 \times 5 \times 4 \times 3 \times 2 \times 1)} = 7.$$

Numéro de l'échantillon	Échantillon	Les fréquences
1	G1, G2, G3, F1, F2, F3	$f_1 = \frac{x_1}{n} = \frac{3}{6}$
2	G2, G3, F1, F2, F3, F4	$f_2 = \frac{x_2}{n} = \frac{4}{6}$
3	G1, G3, F1, F2, F3, F4	$f_3 = \frac{x_3}{n} = \frac{4}{6}$
4	G1, G2, F1, F2, F3, F4	$f_4 = \frac{x_4}{n} = \frac{4}{6}$
5	G1, G2, G3, F1, F2, F4	$f_5 = \frac{x_5}{n} = \frac{3}{6}$
6	G1, G2, G3, F2, F3, F4	$f_6 = \frac{x_6}{n} = \frac{3}{6}$
7	G1, G2, G3, F1, F3, F4	$f_7 = \frac{x_7}{n} = \frac{3}{6}$

On applique les propriétés de l'espérance et de la variance :

1.

$$\begin{aligned} E(f) &= E\left(\frac{X_i}{n}\right) \\ &= \frac{1}{n} E(X_i) \\ &= \frac{1}{n} \times n \times p \\ &= p, \end{aligned}$$

2. – Tirage avec remise (TAR) :

$$\begin{aligned} V(f) &= V\left(\frac{X_i}{n}\right) \\ &= \frac{1}{n^2} V(X_i) \\ &= \frac{1}{n^2} \times n \times pq \\ &= \frac{pq}{n}, \end{aligned}$$

alors

$$\sigma_f = \sqrt{\frac{pq}{n}},$$

– Tirage sans remise (TSR) :

$$\begin{aligned}
 V(f) &= V\left(\frac{X_i}{n}\right) \\
 &= \frac{1}{n^2} V(X_i) \\
 &= \frac{1}{n^2} \times n \times pq \times \frac{N-n}{N-1} \\
 &= \frac{pq}{n} \times \frac{N-n}{N-1},
 \end{aligned}$$

alors

$$\sigma_f = \sqrt{\frac{pq}{n}} \times \sqrt{\frac{N-n}{N-1}}.$$

3 La distribution d'échantillonnage de la variance :

La variance $v(x_i) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ d'un n -échantillon est la réalisation de la variable aléatoire

$V(X_i) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$. On peut se demander si cette variable possède la même propriété que la variable moyenne d'échantillon, c'est-à-dire si l'espérance de $V(X_i)$ est égale à la variance de la population.

1. Espérance de la variable aléatoire $V(X_i)$:

– Tirage avec remise (TAR) :

$$E(V(X_i)) = E\left(\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}\right) = \frac{n-1}{n} \times \sigma^2.$$

– Tirage sans remise (TSR) :

$$E(V(X_i)) = \frac{N}{N-1} \times \frac{n-1}{n} \times \sigma^2.$$

2.

$$E(V(X_i)) = \frac{2(n-1)}{n^2} \times \sigma^4.$$

Conclusion : La moyenne des variances d'échantillon n'est pas la variance de la population, mais la variance de la population multipliée par $\frac{n-1}{n}$. Bien sûr, si n est très grand, ces deux nombres seront très proches l'un de l'autre.